Тээврийн хэрэгслийн ослын эрсдэлийг машин сургалтын аргаар үнэлэх нь

Ганжаргал овогтой Мөнхсүлд
Улаанбаатар хот, Монгол улс

Хураангуй: Энэхүү судалгааны зорилго нь тухайн нэг тээврийн хэрэгсэлийн осол гарах магадлалыг тодорхой интервалд таамаглах pipeline боловсруулхад оршино. Судалгааны үр дүнгээс бидны санал болгосон pipeline нь олон эх сурвалжийн (зөрчил, техникийн үзлэг, эзэмшигч, өмнөх түүх) мэдээллийг нэгтгэн сүүлийн нэг жилд осол гаргах эрсдэлийг эрэмбэлэх боломж олгож байна. ROC-AUC 0.70–0.71 нь төгс таамаглал биш ч, хяналт-шалгалт хийхэд оновчтой түүвэрлэх, өндөр эрсдэлтэй бүлгийг түрүүлж илрүүлэх, даатгалын андеррайтинг тарифын сегментчлэл зэрэгт бодит өгөөж өндөртэй.

Түлхүүр үгс: Зам тээврийн осол, Ангилал, Машин сургалт, ROC–AUC

I. Удиртгал

Зам тээврийн осол нь хүний амь нас, эрүүл мэнд, эдийн засагт өндөр хохирол учруулдаг олон хүчин зүйлт эрсдэлийн үзэгдэл юм. Ослын эрсдэлийг бууруулахад урьдчилан сэргийлэх бодлого, хяналт шалгалт, дэд бүтцийн сайжруулалттай зэрэгцэн осол гарах магадлалыг мэдээлэлд суурилан урьдчилан таамаглах нь бодлого боловсруулагч, даатгалын байгууллага, аюулгүй ажиллагаанд практик ач холбогдолтой (World Health Organization, 2018).

Зам тээврийн ослын эрсдэл нь жолоочийн зан төлөв (хурд, анхаарал сарних, согтуурах), тээврийн хэрэгслийн техникийн нөхцөл, замын дэд бүтэц, цаг агаар, хөдөлгөөний эрчим зэрэг олон хүчин зүйлсийн нийлмэл нөлөөнд тодорхойлогдоно. Уламжлалт статистик аргууд нь тайлбарлах давуу талтай боловч өндөр хэмжээст, шугаман бус, харилцан үйлчлэл ихтэй өгөгдөл дээр таамаглалын нарийвчлалаар хязгаарлагдах тохиолдол бий. Иймээс сүүлийн жилүүдэд машин сургалтын аргууд ослын магадлал, хүндрэлийг урьдчилан таамаглахад түгээмэл ашиглагдах болсон (Hastie et al., 2009; Goodfellow et al., 2016).

Монгол Улсын нөхцөлд зам тээврийн ослын өгөгдөл дээр суурилсан олон загварын харьцуулалт, тэнцвэргүй ангилал, ёс зүй болон хууль зүйн зэрэг асуудлыг системтэй тусгасан судалгааны ажлууд харьцангуй хомс байна. Тиймээс энэхүү судалгаа нь: (i) Монгол Улсын бодит ослын өгөгдөл дээр осол гарах магадлал таамаглах pipeline байгуулах, (ii) Машин сургалтын загваруудыг арга зүй болон үр дүнгийн хүрээнд харьцуулах, (iii) Практик шийдвэр гаргах болон Монгол улсад суурь судалгаа болгох зорилготой.

II. Судлагдсан байдал

Зам тээврийн ослын судалгаанд загварчлалын хоёр том чиглэл зонхилдог: (i) ослын давтамж (crash frequency) болон (ii) ослын хүндрэлийн түвшин (injury severity)-ийг тайлбарлах/таамаглах загварууд. Давтамжийн хувьд Poisson, Negative Binomial болон тэдгээрийн өргөтгөлүүд (Zero-inflated, Hurdle) нь стандартад тооцогддог (Lord and Mannering, 2010). Харин хүндрэлийн түвшин, эсвэл “осол гарах эсэх” зэрэг ангилалтын зорилтот хувьсагчид дээр бинар/олон ангилалттай логит төрлийн загварууд өргөн хэрэглэгддэг (Savolainen et al., 2011).

Зам тээврийн ослын өгөгдөл нь практикт ихэвчлэн тэнцвэргүй ангилалтай байдаг үүний шалтгаан нь осол гарах тохиолдол ховор билээ. Ийм үед зөвхөн Accuracy-гаар үнэлэх нь төөрөгдүүлж болох тул Precision болон Recall, F1-score, ROC-AUC, PR-AUC зэрэг хэмжүүрүүд чухал (He and Garcia, 2009). Мөн эрсдэлийн удирдлага, даатгалын тариф зэрэг хэрэглээнд магадлал нь шууд утгатай тул калибрац (predicted probability vs observed

frequency) сайн байх шаардлагатай. Калибрацын асуудал, магадлалын post-processing (Platt scaling, isotonic regression) зэрэг аргачлалуудыг ангилалтын судалгаанд онцлон авч үздэг (Niculescu-Mizil and Caruana, 2005).

Дээрх судалгааны чиг хандлагыг нэгтгэн дүгнэвэл, (i) уламжлалт статистик загварууд нь тайлбарлах давуу талтай, (ii) машин сургалтын загварууд нь таамаглалын гүйцэтгэлээр давуу байж болох ч overfitting, калибрац, тайлбарлах чадварын асуудал дагуулдаг, (iii) нэг өгөгдөл дээр олон загварыг нэг үнэлгээний протоколоор харьцуулах нь хамгийн зөв практик гэж үзэж болно. Энэхүү судалгаа нь Монгол Улсын бодит өгөгдөл дээр дээрх санааг хэрэгжүүлж, аргачлуудыг харьцуулах олон янзаар туршихийг pipeline түвшинд хийж гүйцэтгэхэд чиглэнэ.

III. Судалгааны арга зүй

A. Өгөгдөл ба эх сурвалж

Судалгаанд Монгол Улсын зам тээврийн ослын бодит өгөгдлийг ашиглав. Машины улсын дугаар болон холбогдох суурь мэдээллийг erthub.mn нээлттэй өгөгдлөөс, зам тээврийн зөрчлийн мэдээллийг autobox.mn эх сурвалжаас тус тус цуглуулав. Харин тээврийн хэрэгсэл сүүлийн нэг жилийн хугацаанд осол гаргасан эсэхийг тодорхойлохдоо MIIS (жолоочийн хариуцлагын албан журмын даатгалын нэгдсэн систем) системд улсын дугаарыг оруулж, N3 итгэлцүүр (сүүлийн 1 жил осолын давтамжаас шалтгаалсан итгэлцүүр) 1-ээс их тохиолдолд сүүлийн нэг жилд осол гаргасан гэж ангилсан.

Судалгааны түүврийн хэмжээ 2460 бөгөөд зорилтот хувьсагч нь сүүлийн нэг жил зам тээврийн осол гаргасан эсэх (0/1) байна. Үүнийг таамаглах зорилгоор нийт 21 тайлбарлагч хувьсагчийг ашигласан. Үүнд: (1) хүч–жингийн харьцаа, (2) дугаарын хязгаарлалттай гарсан өдрийн дундаж тоо, (3) үүргийн зөрчлийн дундаж тоо, (4) зогсоолгүй газар зогссон дундаж тоо, (5) чиглэлийн тээврийн хэрэгслийн эгнээгээр зорчсон тоо, (6) ЗЦГ терминалаар бүртгэгдсэн зөрчлийн дундаж тоо, (7) хурд хэтрүүлсэн дундаж зөрчлийн тоо, (8) гэрлэн дохио зөрчсөн дундаж тоо, (9) хяналтын үзлэгт тэнцээгүй дундаж тоо, (10) эзэмшдэг хувь хүний тоо, (11) эзэмшдэг байгууллагын тоо, (12) өмнөх жил осол гаргасан эсэх, (13) өмнөх жилийн төлбөрийн хэмжээ, (14) суудлын тоо, (15) тээврийн хэрэгслийн нас, (16) жолоочийн жолоо барьсан дундаж жил, (17) хамгийн удаан жолоо барьсан жил, (18) хөдөлгүүрийн хэмжээ, (19) түлшний төрөл, (20) тээврийн хэрэгслийн төрөл, (21) жолооны байрлал зэрэг үзүүлэлтүүд орно.

Дээрх өгөгдөл, хувьсагчдын багцад тулгуурлан сүүлийн нэг жилд осол гаргасан эсэхийг таамаглах зорилготой машин сургалтын pipeline-ийг боловсруулж, загваруудын үнэлгээ болон харьцуулалтыг гүйцэтгэлээ.

B. Өгөгдөл цэвэрлэгээ ба боловсруулалт

Бид өгөгдөлийг боловсруулалт хийхдээ Weight of Evidence (WOE) болон One hot encoder (OHE) ашигласан. WOE нь хувьсагч хувиргалт гэхээс илүү supervised encoder юм. Энэ нь хоёр ангилалт зорилтот хувьсагчтай нөхцөлд, нэг тайлбарлагч хувьсагчийн bin буюу ангилал тус бүр дээр 0 ба 1 ажиглалтуудын харьцааг логарифм хэлбэрээр хэмждэг хувиргалт юм. $Y = 1$ нь bad, $Y = 0$ нь good гэж тэмдэглэе. X-ийн k-р bin дахь good ба bad тоог G_k, B_k, нийт good ба bad тоог $G = \sum_k G_k$, $B = \sum_k B_k$ гэвэл,

$$\mathrm{WOE}_k = \ln\left(\frac{G_k/G}{B_k/B}\right) \tag{1}$$

$\mathrm{WOE}_k > 0$ үед тухайн bin нь харьцангуй бага эрсдэлтэй, $\mathrm{WOE}_k < 0$ үед өндөр эрсдэлтэй гэж тайлбарлана. WOE-ийн mapping-ийг зөвхөн сургалтын өгөгдөл дээр fit хийж, validation болон test дээр ижил mapping-оор transform хийснээр target leakage-ээс сэргийлэв. Мөн $G_k = 0$ эсвэл $B_k = 0$ зэрэг тохиолдолд тогтворжилт сайжруулах зорилгоор жижиг ϵ нэмэх (smoothing) болон ховор түвшнүүдийг нэгтгэх аргыг ашиглав.

Хувьсагчийн ялгах чадварыг IV (Information Value) хэмжүүрээр үнэлэв:

$$\mathrm{IV} = \sum_{k=1}^{K}\left(\frac{G_k}{G} - \frac{B_k}{B}\right)\mathrm{WOE}_k \tag{2}$$

IV өндөр байх тусам тухайн хувьсагч good/bad ангиллыг ялгахад илүү мэдээлэлтэй гэж үзнэ.

C. Ангилалын тэнцвэргүй байдлын асуудал (Class imbalanced problem)

Ангиллын асуудал, ялангуяа ховор тохиолдог ангилалд тулгардаг хамгийн том асуудлуудын нэг бол

ангиллын тэнцвэргүй байдлын асуудал юм. Ангиллын тэнцвэргүй байдал нь өгөгдлийн нэг багц дахь тоо бусад тохиодолуудын тооноос эрс бага байх явдал юм. Ихэнх машин сургалтын алгоритмууд өгөгдлийн багц тэнцвэртэй байх үед илүү үр дүнтэй суралцдаг. Шийдвэрийн хил хязгаарыг үр дүнтэй сурахын тулд цөөнхийн ангийн хангалттай тооны ажиглалтын утга шаардлагтай. Бидний өгөгдөлд 49:51 гэсэн харьцаагаар өгөгдөлийн багц хангагдсан болно.

D. Хэмжээс бууруулалт (Dimensionality reduction)

Autoencoder (AE) нь оролтын өгөгдөл $\mathbf{x} \in \mathbb{R}^d$-ийг бага хэмжээст латент space-д $\mathbf{z} \in \mathbb{R}^p$ $(p < d)$ болгон шахаж (encode), түүнээсээ $\hat{\mathbf{x}}$-ийг сэргээх (decode) байдлаар сурдаг нейрон сүлжээний архитектур юм. AE нь self-supervised сургалт бөгөөд зорилго нь $\hat{\mathbf{x}} \approx \mathbf{x}$ буюу дахин сэргээх алдааг багасгах явдал юм.

a) Архитектур.: Encoder ба decoder гэсэн хоёр хэсэгтэй:

$$\mathbf{z} = f_\theta(\mathbf{x}), \qquad \hat{\mathbf{x}} = g_\phi(\mathbf{z}),$$

энд f_θ нь encoder, g_ϕ нь decoder, θ, ϕ нь сургах параметрүүд.

b) Сургалтын зорилтот функц (reconstruction loss).: Сургалтын өгөгдөл $\{\mathbf{x}_i\}_{i=1}^N$-д AE нь доорх алдааны функцыг хамгийн бага байлган,

$$\min_{\theta,\phi} \ \frac{1}{N}\sum_{i=1}^{N} \mathcal{L}(\mathbf{x}_i, \hat{\mathbf{x}}_i) \ + \ \lambda\, \Omega(\theta, \phi),$$

энд $\mathcal{L}(\cdot)$ нь дахин сэргээх алдаа, бинар хувьсагчид binary cross-entropy), $\Omega(\cdot)$ нь шийтгэл, λ нь жин.

c) Хэмжээс бууруулах (dimensionality reduction) үүрэг.: AE-ийн bottleneck $(p < d)$ бүтэц нь мэдээллийг шахаж, $\mathbf{z}$ латент векторoор өгөгдлийн гол хэв шинжийг илэрхийлдэг. Сургалтын дараа $\mathbf{z}$-ийг:

- шинжийн шахсан төлөөлөл болгон (feature extraction),
- ангилалт/регрессийн загварт оролт болгон

ашиглаж болно. Тусгай тохиолдолд, шугаман AE ба ℓ_2 алдаатай сургалт нь PCA-тэй ойролцоо үр дүн өгдөг.

d) Тогтворжуулсан AE хувилбарууд (товч).: AE-ийн ерөнхий санааг өргөтгөсөн түгээмэл хувилбарууд:

- Denoising AE: $\tilde{\mathbf{x}}$-ооc (white noise ихтэй) $\mathbf{x}$-ийг сэргээж сургана энэ нь илүү бат бөх (robust) болно.
- Sparse AE: $\mathbf{z}$-д sparsity penalty (жиш., ℓ_1, эсвэл KL) нэмнэ энэ нь илүү тайлбарлагдахуйц, шугаман latent гаргах боломжтой.

E. Загвар 1: Шийдвэрийн мод (Decision tree)

Шийдвэрийн модны арга нь ангиллын зориулалтаар түгээмэл ашигладаг. Өгөгдсөн ажиглалтын утга аль бүлэгт орохыг урьдчилан таамаглахдаа тухайн бүлгийн сургалтын өгөгдлүүдийн дундаж утгыг ашигладаг. Таамаглалын огторгуйг тодорхой тооны бүлгүүдэд хэсэглэн хуваах зарчмыг баримталдаг учраас шийдвэрийн модны арга гэж нэрлэдэг. Ангиллын болон регрессийн мод нь түүхэн өгөгдлийг мод хэлбэрийн бүтэц зохион байгуулалттайгаар үнэлж шийдвэр дэмжихэд ашигладаг ангиллын арга юм (Breiman et al., 1984). Энэхүү аргын зорилго нь урьдчилан таамаглах эсвэл ангилах боломжийг олгодог логик нөхцлүүдийн багцыг тодорхойлоход оршино. Шийдвэрийн моднуудыг байгуулахдаа Хи-квадрат, Жини (gini) индекс, Entropy-ийг тус тус ашигладаг (Breiman et al., 1984).

F. Загвар 2: Санамсаргүй ой (Random forest)

Санамсаргүй ойн арга нь шийдвэрийн модны аргыг бага зэрэг сайжруулсан арга юм. Энэ аргын хувьд дахин давтан сонгосон сургалтын олонлогуудыг ашиглан шийдвэрийн модыг байгуулдаг. Эдгээр шийдвэрийн модыг байгуулахдаа p тооны оролтын хувьсагчаас модны хуваалтэд ашиглагдах m тооны үзүүлэлтийг санамсаргүйгээр сонгож авдаг. Өөрөөр хэлбэл эдгээр сонгон авсан m тооны оролтын хувьсагчдыг хуваалт бүрд ашиглах ба $m \approx \sqrt{p}$ байна.

Санамсаргүй ойн алгоритмын алхмууд: Санамсаргүй ойд p тооны өгөгдлийн багцаас m тооны санамсаргүй өгөгдлөөс сонгож авна. (i) Шийдвэрийн модыг сонгож авсан өгөгдөл тус бүр дээр байгуулна, (ii) Шийдвэрийн мод бүрд үр дүнгийн гаралтын утга гарна, (iii) Эцсийн үр дүнг ангиллын бол регрессийн хувьд давуу шийд эсвэл дундажаар үндэслэн,авна.

G. Загвар 3: Тулгуур векторын машин (SVM)

Тулгуур вектор машины ангилал нь ангилалтын өгөгдлийг гипер хавтгайн аль талд нь байгаагаас хамаарч ангилал хуваарилна. Гипер хавтгай сонгоход сургалтын өгөгдлүүдийн ихэнх нь 2 ангилыг хэрхэн хуваагдан байгааг харгалзан үзэх ба харин цөөн тооны

өгөгдлийг үл харгалзан үздэг. Учир нь энэхүү гипер хавтгай нь дараах оптимизацийн бодлогыг шийднэ.

$$\max_{\beta_i} M \tag{3}$$

$$\sum_{j=1}^{p} \beta_j^2 = 1 \tag{4}$$

$$y_i(\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}) \geq M(1 - \varepsilon_i) \tag{5}$$

Энд M нь маржингийн өргөн.

$$\varepsilon_i > 0, \qquad \sum_{i=1}^{n} \varepsilon_i \leq C \tag{6}$$

Энд C нь эерэг параметр, M нь маржингийн өргөн бөгөөд түүний утга аль болох их байхаар авна. Дээрх бодлогыг бодсоны дараа туршилтын өгөгдөл x^*-г өмнөхтэй адил уг гипер хавтгайн аль талд нь харьцангуй байгаагаар нь ангилна. Өөрөөр хэлбэл, $f(x^*) = \beta_0 + \beta_1 x_1^* + \cdots + \beta_p x_p^*$-ийн тэмдгийг ашиглан ангилал хийнэ.

H. Загвар 4: Ложит регресс

Ложит регрессийн загварыг:

$$\Pr(y = 1 \mid x) = \sigma(\beta_0 + x^\top \beta) \tag{7}$$

хэлбэрээр тодорхойлно. Параметрүүдийг хамгийн их үнэний аргаар үнэлж, overfitting-ээс сэргийлэхийн тулд L2 (ridge) болон/эсвэл L1 (lasso) шийтгэл ашиглах хувилбаруудыг туршина:

$$\min_{\beta} \ \mathcal{L}(\beta) + \lambda \|\beta\|_2^2 \quad \text{эсвэл} \quad \min_{\beta} \ \mathcal{L}(\beta) + \lambda \|\beta\|_1, \tag{8}$$

энд $\mathcal{L}(\beta)$ нь бинар cross-entropy (log-loss) алдагдал байна.

I. Загвар 5: Хиймэл нейрон сүлжээ (MLP)

Нейрон сүлжээний суурь архитектурыг олон давхар перцептрон (MLP) хэлбэрээр авч үзнэ. Гаралтын давхаргад sigmoid ашиглан магадлал гаргана:

$$\hat{p}(x) = \sigma(f_\theta(x)), \tag{9}$$

алдагдлын функц нь бинар cross-entropy:

$$\mathcal{L}(\theta) = -\sum_{i=1}^{n} [y_i \log \hat{p}(x_i) + (1 - y_i) \log(1 - \hat{p}(x_i))] \tag{10}$$

Сургалтад Adam optimizer, early stopping, dropout, weight decay зэрэг шийтгэлийн аргуудыг ашиглан загварын хөгжих чадварыг сайжруулна (Goodfellow et al., 2016).

J. Загвар 7: K-хамгийн ойрын хөрш (KNN)

Бидэнд $(x_i)_{i\in[1,n]}$ сургалтын өгөгдлөөс бүрдсэн D сургалтын багц байна гэж үзье. Жишээнд хувьсагчдын багцыг F-ээр тайлбарлах ба тоон утгатай хувьсагчдыг $[0, 1]$ утгаар илэрхийлсэн. Сургалтын өгөгдлийн тохиолдол бүрийг $y_i \in Y$ гэсэн ангиллын шошготоогоор тэмдэглэсэн. Бидний зорилго бол үл мэдэгдэх жишээ q-г ангилах явдал юм. $x_i \in D$ бүрийн хувьд q ба x_i хоорондын зайг дараах байдлаар тооцоолж болно.

$$d(q, x_i) = \sum_{f \in F} w_f \, \delta(q_f, x_{if}) \tag{11}$$

Дээрх томьёонд оролтын хувьсагчдын (F) нийлбэр тооцсон ба w_f нь хувьсагч тус бүрийн жинг илэрхийлсэн. Зайн хэмжүүрээр тасралттай, тасралтгүй хувьсагчдыг тооцоолох боломжтой.

$$\delta(q_f, x_{if}) = \begin{cases} 0, & f \text{ салангид, } q_f = x_{if}, \\ 1, & f \text{ салангид, } q_f \neq x_{if}, \\ |q_f - x_{if}|, & f \text{ тасралтгүй.} \end{cases} \tag{12}$$

Дээрх байдлаар зайн хэмжүүрт үндэслэн хамгийн ойрын k хөршийг сонгоно (Cunningham and Delany, 2020; Cover and Hart, 1967).

K. Загвар 8: Gradient Boost ангилагч

Gradient Boost нь ангиллын олон регрессийн загваруудад тохиромжтой (Friedman, 2001). Энэ алгоритм нь Gradient Boost аргаар loss багасгах замаар бинар шийдвэрийн модны loss-ийг давталттайгаар байгуулдаг. Давталт бүрд одоогийн таамаглалтай холбоотой алдааны функцийн градиентийн сөрөг утгыг тооцоолж шинэ модыг тохируулна. Сурах хурд (learning rate) нь градиентийг багасгах алхмын хэмжээг тодорхойлдог. Урьдчилан тогтоосон тооны мод нэмэх эсвэл нэгдэх шалгуурыг хангах хүртэл процесс давтагдана. Үр дүн таамаглахдаа тооцоолсон бүх модны таамаглалыг нэгтгэдэг ба ингэснээр өндөр нарийвчлалтай, найдвартай загварууд бий болдог. Энэхүү загвар нь дараах математик томьёогоор тодорхойлогдоно.

Сургалтын өгөгдөл $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$ ба $y_i \in \{0, 1\}$ өгөгдөнө.

$$F(x) = \sum_{t=1}^{T} f_t(x) \tag{13}$$

Энд $f_t(x)$ нь шийдвэрийн мод, санамсаргүй ой зэрэг ангиллын алгоритмууд байна.

$$F_0(x) = \sigma(p), \quad p = \frac{1}{n} \sum_{i=1}^{n} y_i \tag{14}$$

Тиймээс алдааны функц нь binary cross entropy байна. Энэ функц тухайн загварын сургалтын явцад гиперпараметрийн үнэлгээний утгаас хамаарч Gini зэрэг функцээр солих боломжтой.

$$r_i^{(t)} = y_i - \hat{p}_i^{(t-1)} \quad \text{энд} \quad \hat{p}_i^{(t-1)} = \sigma\big(F_{t-1}(x_i)\big) \tag{15}$$

Сөрөг градиантын утгыг $\sigma(z)$ сигмоид функцээр дахин хувиргаж загварыг шинэчилнэ.

$$F_t(x) = F_{t-1}(x) + \nu f_t(x) \tag{16}$$

Энд $\nu \in (0, 1)$ нь 0–1-ийн завсар дахь суралцах хурд байна. Эндээс ангиллын загвар дараах томьёогоор илэрхийлэгдэнэ.

$$\hat{p}(x) = \sigma\big(F_T(x)\big) = \frac{1}{1 + e^{-F_T(x)}} \tag{17}$$

L. Загвар 9: XGBoost ангилагч

Энэ нь уламжлалт градиентийн алгоритмтай харьцуулахад олон сайжруулалтыг санал болгодог бөгөөд ангиллын болон регрессийн шинжилгээнд аль алинд нь тохиромжтой алгоритм юм. Энэ төрлийн уламжлалт алгоритмуудаас ялгаатай нь XGBoost-ын алдаа тооцох системд загвар хэт суралцахаас (overfilling problem) сэргийлэх зохицуулалтыг нэвтрүүлсэн (Chen and Guestrin, 2016). Уг загварын loss функц нь доорх хэлбэртэй байна.

$$\mathcal{L}(x) = \sum_{i=1}^{\infty} \ell\left[y_i, f(x_i)\right] + \Omega(f) \tag{18}$$

M. Загвар 10: LightGBM (LGBM)

LightGBM нь Gradient Boost шийдвэрийн модод суурилсан маш хурдан алгоритм бөгөөд тасралтгүй хувьсагчдыг histogram аргаар bin-лэж split хайдаг. Мод ургуулахдаа түвшин-суурьтай (level-wise) бус leaf-wise (best-first) стратеги ашигладгаараа онцлог бөгөөд энэ нь олон тохиолдолд нарийвчлалыг сайжруулах боловч num leaves, max depth зэрэг параметрээр хэт суралцах эрсдэлийг хянана.

Сургалтын өгөгдөл $(x_i, y_i)_{i=1}^{n}$, $y_i \in \{0, 1\}$ үед загварын нийлбэр хэлбэр:

$$F(x) = \sum_{t=1}^{T} f_t(x), \tag{19}$$

бинар ангилалд магадлал:

$$\hat{p}(x) = \sigma(F(x)) = \frac{1}{1 + e^{-F(x)}}. \tag{20}$$

Зорилтот функц нь алдаа ба шийтгэлийн нийлбэр:

$$\mathcal{L} = \sum_{i=1}^{n} \ell\left(y_i, \hat{p}(x_i)\right) + \sum_{t=1}^{T} \Omega(f_t). \tag{21}$$

LightGBM нь 2-р эрэмбийн ойролцоолол ашиглан split-ийн ашиг (gain)-ийг тооцно. Градиент ба Хессиан:

$$g_i = \frac{\partial \ell}{\partial F(x_i)}, \qquad h_i = \frac{\partial^2 \ell}{\partial F(x_i)^2}. \tag{52}$$

Зангилааны нийлбэрүүд $G = \sum g_i$, $H = \sum h_i$ гэж тэмдэглэвэл оптимал навчийн утга:

$$w^* = -\frac{G}{H + \lambda}, \tag{22}$$

харин I_L, I_R хуваалтын gain:

$$\text{Gain} = \frac{1}{2}\left(\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{G^2}{H + \lambda}\right) - \gamma. \tag{23}$$

Практикт хамгийн их нөлөөтэй тохируулгууд нь learning_rate, n_estimators, num_leaves, max_depth, min_data_in_leaf, мөн шийтгэлийн λ ба γ байдаг.

N. Шатлалт загвар 1: Platt scaling

Platt scaling нь ангилагчийн гаргасан оноо (score) буюу decision function-ийн утгыг магадлал болгон калибрлах арга юм. Ялангуяа SVM зэрэг margin-based загваруудын гаралт нь шууд $P(y = 1 \mid x)$ биш тул, оноог магадлал болгон хувиргах шаардлага үүсдэг.

Platt scaling нь загварын оноо $s(x)$ дээр ложистик (sigmoid) функц тааруулж,

$$\hat{p}(y = 1 \mid x) \;=\; \sigma\big(A\, s(x) + B\big) \tag{24}$$

хэлбэрийн хувиргалтыг ашиглана. Энд A ба B нь калибрацийн өгөгдөл дээр лог-алдагдал (negative log-likelihood, log-loss)-ыг хамгийн бага болгох замаар үнэлэгдэнэ. Ингэснээр загварын эрэмбэлэлт (ranking) ерөнхийдөө хадгалагдах боловч, $\hat{p} = 0.8$ гэж үнэлсэн ажиглалтуудын 80% нь үнэхээр $y = 1$ байх зэрэг ангилал сайжирна.

О. Шатлалт загвар 2: Isotonic regression

Isotonic regression нь ангилагчийн гаргасан оноо (score) $s(x)$-г магадлал $\hat{p}(y = 1 \mid x)$ болгон монотон (non-decreasing) хувиргалтаар калибрлах параметргүй (non-parametric) арга юм. Platt scaling шиг урьдчилан тогтсон sigmoid хэлбэр таамаглахгүйгээр, зөвхөн оноо өсөх тусам $y = 1$ байх магадлал өснө гэсэн логик шаардлагыг (f функц монотон өсөх) тулгуур болгон ашигладаг.

Ерөнхийдөө isotonic regression нь дараах монотон функц $f(\cdot)$-г олно,

$$\hat{p}_i \;=\; f(s_i), \qquad \text{энд } f \text{ нь non-decreasing.} \tag{25}$$

Калибрацийн өгөгдөл $(s_i, y_i)_{i=1}^{n}$ дээр квадрат алдагдлыг (Brier-type loss) хамгийн бага болгох монотон ойролцооллыг бодно:

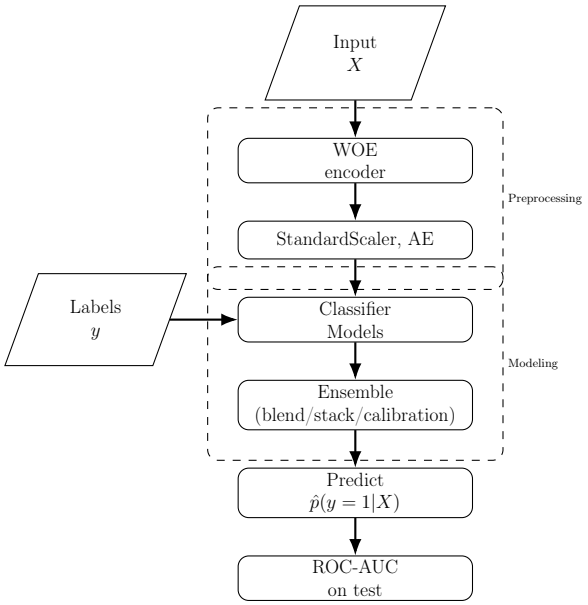
$$\min_{f \,\in\, \mathcal{F}_{inc}} \sum_{i=1}^{n} \big(y_i - f(s_i)\big)^2, \tag{26}$$

энд $\mathcal{F}_{inc}$ нь бүх non-decreasing функцүүдийн олонлог юм. Энэ оптимизацын шийд ихэвчлэн piecewise-constant (шаталсан) хэлбэртэй гардаг бөгөөд Pool-Adjacent-Violators Algorithm (PAVA)-аар тооцно. Үр дүнд нь онооны интервал бүрт тогтвортой магадлал оноож, харин интервалыг өсөх дарааллаар шугаман функц нэмнэ.

Isotonic calibration нь өгөгдөл хангалттай их, эсвэл score–probability харилцаа sigmoid-оос ихээхэн хэлбэрийн хувьд өөр үед (non-logistic) давуу талтай. Гэвч уян хатан чанар өндөр тул калибрацийн багц жижиг үед overfitting үүсэх эрсдэлтэй. Иймээс isotonic regression-ийг тусдаа калибрацийн багц дээр сургах, эсвэл cross-validation ашиглан out-of-fold калибраци хийх нь зүйтэй.

Р. Сургалтын байгуулалт (Pipeline)

Бид өгөгдөлөө train (49%), val_model (21%), val_ens (15%), test_final (15%) гэж дөрвөн хэсэгт хуваасан. train хэсэгт моделуудаа сурган val_model хэсэгт early stop, parameter tune хийнэ, тэгээд моделийн эцсийн үр дүнг val_ens дээр гарган үүний дараа ensemble хэсэгрүү орно ensemble-ийн хөгжүүлэлтийн хэсгийг val_ens болгон шилжүүлэн үүний дараа эцсийн үр дүнг test_final дээр гаргана. Манай pipeline доорх байдалтай харагдана.



Зураг 1. Сургалтын байгуулалт буюу Pipeline

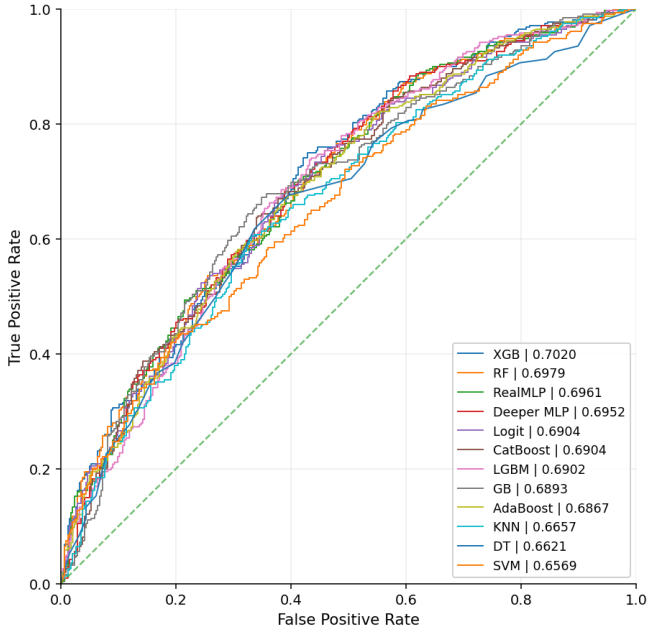
Гэхдээ уг pipeline-ний сул тал нь бага өгөгдөл дээр Deep learnig суурьтай загвар муу ажилдаг тул Bias болон вариац ихтэй гарах магадлалтай. Давуу тал нь leakage-ээс сэргийлэн олон төрлийн суурь загваруудыг нэг стандартаар туршин хөгжүүлэх боломж олгодог. Сайжруулах боломж нь out of fold (OOF) ашиглан train өгөгдөлөө ихэсгэнэ. Ингэсэнээр deep learnig суурьтай моделийн үр дүн эрс сайжрах боломжтой.

IV. Үр дүн

Загваруудын үр дүнгээс харахад ашигласан бүх ангилагч загваруудын гүйцэтгэл санамсаргүй таамаглалын шугамаас тогтвортой өндөр байрлаж, сүүлийн нэг жилд осол гаргасан эсэхийг тодорхой хэмжээнд ялган ангилах чадвартай болохыг харууллаа. Загваруудын ROC-AUC үзүүлэлт 0.657–0.702-ийн хооронд хэлбэлзсэн бөгөөд нийт дүнгээр ялгах чадвар дунд түвшинд байгааг илтгэнэ.

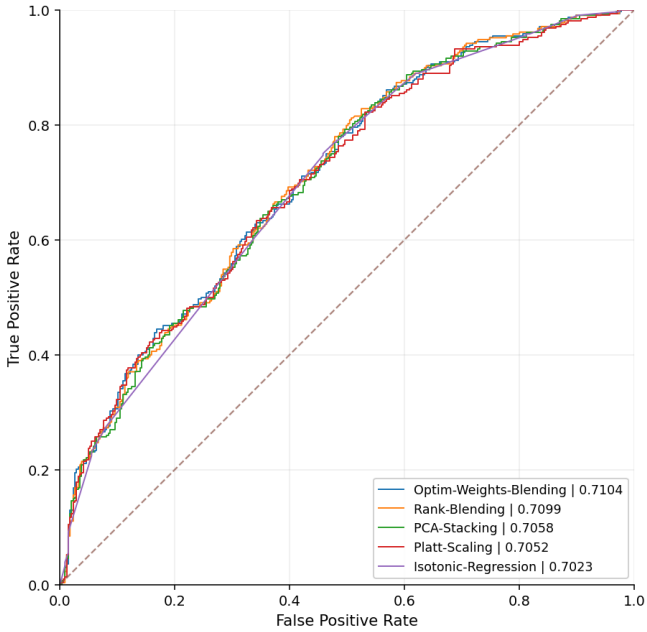
XGBoost загвар хамгийн өндөр гүйцэтгэлтэй гарсан бол Random Forest , RealMLP , Deeper MLP зэрэг загварууд түүнтэй ойролцоо үзүүлэлттэй байсан нь загваруудын хоорондын ялгаа харьцангуй бага байж болохыг илэрхийлнэ. Үүнийг ROC муруйнуудын ихэнх мужид давхцал өндөр ажиглагдсанаар нэмэлтээр нотолж болох бөгөөд тухайн өгөгдөл, сонгосон хувьсагчдын хүрээнд загварууд ижил төстэй мэдээлэл ашиглан шийдвэр гаргаж, түвшин ойролцоо гүйцэтгэлд хүрсэн байх магадлалтай.

Харин KNN , Decision Tree, SVM зэрэг загваруудын гүйцэтгэл харьцангуй доогуур байгаа нь өгөгдөл дэх хамаарал, харилцан үйлчлэл (interaction) болон шугаман бус бүтэцтэй хандлагыг tree-based boosting болон deep learning төрлийн загварууд илүү үр ашигтай байгаатай холбоотой байж болно.



Зураг 2. Загваруудын үр дүн

Гэхдээ сайн ажиглавал загварын төрөл болгон өөрийн гэсэн давуу threshold–той харагдаж байна. Хамгийн сайн нэг загвар ашиглахын оронд ensemble аргачлалыг хэрэглэснээр үр дүнг улам сайжруулах боломжтой гэж үзсэн бөгөөд энэхүү аргачлалыг хэрэгжүүлэхэд Figure 3 дээрх үр дүн гарсан.



Зураг 3. Ensemble-ийн үр дүн

Optim-Weights Blending хамгийн өндөр ROC-AUC үзүүлэлттэй (AUC=0.7104) гарсан бөгөөд Rank-Blending (AUC=0.7099) түүнтэй бараг ялгаагүй ойролцоо гүйцэтгэл үзүүлэв. Харин PCA-Stacking (AUC=0.7058) болон Platt Scaling (AUC=0.7052) нь харьцангуй доогуур үзүүлэлттэй байсан ч суурь загваруудтай харьцуулахад гүйцэтгэлийг тодорхой хэмжээнд сайжруулсан байна. Мөн Isotonic Regression-ын AUC (0.7023) нь бусад ensemble хувилбаруудаас доогуур байгаа хэдий ч муруйн хэлбэрийн хувьд нийт мужид тогтвортой, магадлалын калибраци (calibration)-ын чанарыг сайжруулаж байна.

V. Дүгнэлт

Нэгтгэнэ дүгнэхэд бидны санал болгож буй pipeline нь тээврийн хэрэгслийн зөрчил, техникийн үзүүлэлт, эзэмшигчийн бүтэц, өмнөх түүх зэрэг олон эх сурвалжийн мэдээллийг нэгтгэн сүүлийн нэг жилд осол гаргах эрсдэлийг эрэмбэлэх боломжтой гэдгийн тест хэсэг дээр харуулж байна. ROC-AUC-ийн түвшин дунд зэрэг буюу суурь загварууд 0.70 орчим, ensemble хувилбарууд 0.71 байгаа нь осол гаргах эсэхийг 100% үнэн үнэлэх түвшин биш боловч, практикт хамгийн үнэ цэнтэй хэрэглээтэй, хяналт шалгалтыг оновчтой түүвэрлэх, өндөр эрсдэлтэй бүлгийг урьдчилан илрүүлэх, даатгалын андеррайтинг болон тарифын сегментчлэлийг сайжруулах зэрэг шийдвэр гаргалтад хангалттай мэдээлэл өгч чадна. Ялангуяа энэхүү загварын давуу тал нь эерэг тохиолдлыг алдалгүй барих зорилгоор шийдвэрийн босгыг тохируулснаар цагдаа, хяналтын байгууллага, тээврийн бодлого боловсруулагчдын хэрэгжүүлдэг зорилтот хяналтад шууд ашиглагдах боломжтой юм. Гэсэн хэдий ч практикт үр дүнтэй нэвтрүүлэхийн тулд загварыг зөвхөн AUC үзүүлэлтээр хязгаарлахгүйгээр өөр хэмжүүрүүдээр баталгаажуулах шаардлагатай. Тухайлбал, хамгийн өндөр эрсдэлтэй гэж үнэлэгдсэн дээд 5–10%-д багтсан тээврийн хэрэгслүүдийн дундах ослын давтамж бодитоор хэдэн хувиар өндөр байна вэ? , өгөгдсөн түүврийн нөөцөөр хэдэн осолын тохиолдлыг урьдчилан илрүүлж байна вэ?, анхааруулга өгсөн тохиолдлын хэд нь үнэхээр осолд ордог вэ? зэрэг хэмжүүрээр үнэлэх нь бодит ашиг тусыг илүү тодорхой харуулна. Мөн өгөгдөл нь олон эх сурвалжаас ирж буй тул цаг хугацааны явцад зөрчлийн хэв маяг, дүрэм журам, бүртгэлийн чанар өөрчлөгдөхөд загварын гүйцэтгэл буурах эрсдэлтэй; иймээс тасралтгүй шинэчлэлт (monitoring), дахин сургалт (retraining), калибраци хийх гэх мэт нэмэлт шаардлагатай. Нийт дүнгээр, энэхүү судалгаа нь ослын эрсдэлийг урьдчилан илрүүлэх асуудлыг бодит өгөгдлөөр шийдвэрлэх боломжийг харуулсан бөгөөд зөв босго сонголт, тогтмол хяналт-шинэчлэлт, бодит үйл ажиллагааны KPI-гаар баталгаажуулалт хийсэн нөхцөлд бодлого, хяналт, даатгалын үйл ажиллагаанд шууд нэвтрүүлэх боломжтой практик ач холбогдолтой гэж дүгнэж болно.

Ашигласан ном

Breiman, L., Friedman, J. H., Olshen, R. A., and Stone, C. J. (1984). Classification and Regression Trees. Wadsworth, Belmont, CA.

Chen, T. and Guestrin, C. (2016). Xgboost: A scalable tree boosting system. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD), pages 785–794.

Cover, T. M. and Hart, P. E. (1967). Nearest neighbor pattern classification. IEEE Transactions on Information Theory, 13(1):21–27.

Cunningham, P. and Delany, S. J. (2020). k-nearest neighbour classifiers: A tutorial. arXiv preprint arXiv:2004.04523.

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. The Annals of Statistics, 29(5):1189–1232.

Goodfellow, I., Bengio, Y., and Courville, A. (2016). Deep Learning. MIT Press, Cambridge, MA.

Hastie, T., Tibshirani, R., and Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction. Springer, New York, 2 edition.

He, H. and Garcia, E. A. (2009). Learning from imbalanced data. IEEE Transactions on Knowledge and Data Engineering, 21(9):1263–1284.

Lord, D. and Mannering, F. (2010). The analysis of crash-frequency data: A review and an assessment of statistical approaches. Transportation Research Part A: Policy and Practice, 44(5):291–305.

Niculescu-Mizil, A. and Caruana, R. (2005). Predicting good probabilities with supervised learning. In Proceedings of the 22nd International Conference on Machine Learning (ICML), pages 625–632.

Savolainen, P. T., Mannering, F. L., Lord, D., and Quddus, M. A. (2011). The statistical analysis of highway crash-injury severities: A review and assessment of methodological alternatives. Accident Analysis & Prevention, 43(5):1666–1676.

World Health Organization (2018). Global status report on road safety 2018. Technical report, World Health Organization, Geneva, Switzerland. WHO-NMH-NVI-18.20.