QLoRA аргаар сургасан том хэлний загвараар шүүхийн шийдвэрээс бүтэцлэгдсэн өгөгдөл олборлох нь

Г. Мөнхсүлд*

Хураангуй

Энэхүү судалгаанд Монгол хэл дээрх шүүхийн шийдвэрээс хохирол, нөхөн төлөлт, үлдэгдэл, огноо гэх мэт мэдээллийг тогтмол бүтэцтэй хүснэгтэн өгөгдөл болгон олборлох асуудлыг QLoRA аргаар судлав. Судалгаанд Muse-Glimmer-30B, Gemma-4 31B, Qwen3.8-27B загваруудын суурь жинг (base weights) 4 битийн NF4 хэлбэрээр жижигрүүлж (quantization), LoRA-ыг 24 GB санах ойтой график кард (GPU) дээр сургасан. Нийт 657 эрүүгийн хэргийг бүлгээр сургалтын (training) 500, хөгжүүлэлтийн (development) 59, шалгалтын (test) 98 гэж хуваан, 13 баганатай нэг шүүхийн шийдвэр нь нэг мөр гаралттай даалгавар өгөх эмпирик туршилт хийв. Эмпирик үр дүнгээс QLoRA сургалтын дараа багануудыг үнэн таамагласан хувь (field accuracy) Muse-30B, Gemma4-31B, Qwen3.8-27B загварт тус тус 88.3%, 90.1%, 90.7%; бүх мөр зөв таамагласан хувь (exact match) 33.7%, 41.8%, 41.8%; мөнгөн дүнтэй багануудын зөв таамагласан хувь 81.9%, 86.0%, 87.5%; байв. Гэсэн хэдий ч огноо нь тодорхойгүй болон өндөр мөнгөн дүн дээр бодит хэрэглээнд хүний хяналт (human review) шаардлагатай гэж үзэж байна. Нэмэлтээр өөр зүйл ангийн 49 шийдвэрийг хүн болон Opus 5.5 загвараар давхар хянасан өгөгдөл дээр туршиж, үүнээс таахад хялбар CID ба CONF-ийг хассан 11 баганаар үнэлэхэд тус тус 73.8%, 72.5%, 78.1% зөв таамагласан гарсан мөн үндсэн үнэлгээ хийсэн шийдвэртэй төстэй шүүхийн шийдвэрүүдэд илүү өндөр үр дүн үзүүлжээ. Практик ач холбогдол нь QLoRA-аар сургасан загвар хэдэн мянган шүүхийн шийдвэрээс олборлосон хүснэгт датаны эхний шатны хувилбар үүсгэх, хүний хяналтыг засах шаардлагатай багана, мөр лүү чиглүүлэхэд туслах хэрэгсэл болгон ашиглах ба цаашид илүү том загвар, дата дээр хөгжүүлэж сайжруулах боломжтой. Уг өгөгдөл олборлох арга зүй, сургах өгөгдөлийн чанарыг сайжруулан найдвартай өгөгдөл үүсгэж чадвал бодлого боловсруулагч, судлаачдын цаашдын судалгаа, шинжилгээ болон шийдвэр гаргалтыг дэмжих өгөгдөлийн эх сурвалж болох боломжтой.

Түлхүүр үг: QLoRA, том хэлний загвар, өгөгдөл олборлолт, Монгол хэл, шүүхийн шийдвэр, NLP

*МУИС–МТЭС, Хиймэл оюун, Магистр-I. Цахим шуудан: 26M1NUM0238@stud.num.edu.mn, Утас: 95777123

1 Удиртгал

Шүүхийн шийдвэр нь их хэмжээний, бүтэц нь тодорхойгүй (unstructured) текстээс бүрдсэн байдаг бөгөөд нэг шүүхийн шийдвэрт ижил төрлийн боловч өөр утгатай олон тоон мэдээлэл зэрэгцэн оршдог. Тухайлбал, нийт хохирол, шийдвэр гарахаас өмнө бодитоор төлсөн мөнгө, төлөөгүй дүн, шүүхээс гаргуулахаар тогтоосон дүн нь утгын хувьд ялгаатай ойлголтууд юм. Эдгээрийг нэг төрлийн мөнгөн дүн гэж авч үзвэл нөхөн төлөлтийн хувь, үлдэгдэл хохирол болон уг өгөгдөлийг цааш ашиглах үед зөрүү үүсэх эрсдэлтэй. Үүнтэй адил шийдвэрийн кессэд огноо дурдагдсан нь тухайн огноог гэмт үйлдэл дууссан, шүүх хэрэг хүлээн авсан эсвэл шийдвэр гарсан өдөр гэж шууд үзэх үндэслэл болохгүй. Иймээс учраас хиймэл оюун байтугай хүн алдах тохиолдол их байдаг гэвч нэг зүйлд мэргэших нь тухайн алдааг ихээхэн бууруулдаг билээ.

Сүүлийн жилүүдэд том хэлний загварыг (large language model) бүтэцгүй кессээс мэдээлэл олборлох (information extraction), асуултад хариулах, текстийг тогтмол форматад хөрвүүлэх зэрэг даалгаварт ашиглах судалгаа эрчимжиж байна. Гэсэн хэдий ч хэдэн арван тэрбум параметртэй загварыг бүх жингээр нь нарийн тохируулан сургах (full fine-tuning) нь GPU санах ой болон тооцооллын ихээхэн нөөц шаарддаг. LoRA нь суурь жинг тогтмол (frozen) хадгалж, бага ранктай (low-rank) нэмэлт матрицуудыг сургах замаар шинэ даалгаварт дасан зохицох боломж бүрдүүлдэг [1]. Харин QLoRA нь жижигрүүлсэн суурь загвар дээр LoRA параметрийг сургаж, санах ойн хэрэглээг бууруулах боломж олгодог [2].

Чанарын судалгаа (qualitative research) дотор кейс судалгааны аргачлал (case study method) гэж байдаг бөгөөд энэ нь кессүүдийг уншиж тохиолдол бүрийг задлан шинжилдэг. Гэвч энэ нь тоон судалгааны (quantitative research) арга шиг маш олон тохиолдолыг зэрэг судлах боломжгүй байдаг. Монгол улсын хэмжээнд нээлттэй шүүхийн шийдвэрийн өгөгдлийн хэмжээ нь,

Хүснэгт 1: Шүүхийн шийдвэрийн цахим сан дахь бүртгэлийн тоо

Шүүхийн төрөл	Анхан шат	Давж заалдах шат	Хяналтын шат
Эрүүгийн хэрэг	159,828	30,813	4,998
Иргэний хэрэг	367,607	41,862	13,786
Захиргааны хэрэг	24,866	11,493	4,354

байгаа бөгөөд шийдвэр нь ихэвчлэн тогтсон бүтэцгүй текстэн хэлбэрээр хадгалагддаг тул статистик болон тоон шинжилгээнд шууд ашиглахад хүндрэлтэй. Иймээс энэхүү **судалгааны зорилго** нь шүүхийн шийдвэрээс тогтмол бүтэцтэй хүснэгтэн өгөгдөл болгон автоматаар олборлох боломжтой эсэхийг QLoRA аргаар сургасан том хэлний загваруудын тусламжтайгаар туршин харуулахад оршино. Хэрэв боломжтой бол цаашид шүүхийн шийдвэрийн томоохон текстэн санг статистик, эконометрик болон машин сургалтын (machine learning) судалгаанд ашиглах бүтэцлэгдсэн өгөгдлийн (structured data) эх сурвалж болгон хувиргах боломжтой.

Иймээс энэхүү судалгааны зорилгод нийцсэн эмпирик туршилтыг Монголын шүүхийн шийдвэрээс бэлтгэсэн текстэн оролтыг 13 баганатай, машинд шууд ойлгох боломжтой (machine-parsable) нэг мөрийн тоон гаралт болгон хувиргах загварыг QLoRA аргаар сургаж, түүний зөв таамаглал, алдааны бүтэц болон тооцооллын зардлыг хамтад нь үнэлэх болно. Үүний тулд 30 тэрбум орчим параметртэй загварыг олон мянган токентой жишээгээр нэг 24 GB GPU дээр сургах боломж, QLoRA сургалтын дараах чанарын өөрчлөлт, мөн алдаа төвлөрч буй багана болон нөхцөлийг туршилтаар тодорхойлов.

Дээрх үндэслэлд тулгуурлан энэхүү судалгаа нь дараах хувь нэмрийг оруулж байна. Нэгдүгээрт, хохирол, нөхөн төлөлт, үлдэгдэл, огноо болон хөдөлмөрийн харилцааны шинжийг ялгасан 13 баганатай M1 гаралтын схемийг тодорхойлов. Хоёрдугаарт, Muse-Glimmer-30B, Gemma-4 31B, Qwen3.8-27B загваруудыг 24 GB VRAM бүхий нэг GPU дээр урт оролтоор сургахын тулд жижигрүүлэл, завсрын төлөвийг дахин тооцоолох (gradient checkpointing), CPU руу шилжүүлэлт

болон архитектурт тохирсон хэсэгчилсэн тооцоог (chunking) хослуулсан. Гуравдугаарт, суурь болон QLoRA хувилбаруудыг ижил шалгалтын жишээнд үнэлж, форматын зөв байдал (format validity), агуулгын зөв таамаглал, мөн мөнгөн дүн ба огнооны алдааг тусад нь шинжилсэн.

1.1 Судлагдсан байдал

Шүүхийн шийдвэр боловсруулах чиглэлд тухайн салбарын өгөгдлөөр урьдчилан сургасан хэлний загвар (domain-specific pre-trained language model), нэрлэсэн нэгж (named entity) болон тэдгээрийн хамаарлыг (relation) олборлох арга, мөн цөөн параметр шинэчлэх (parameter-efficient fine-tuning, PEFT) замаар загварыг тухайн даалгаварт тохируулах хандлагууд өргөн судлагдаж байна. Монгол хэлний хууль зүйн байгалийн хэл боловсруулалтын (NLP) хүрээнд Халтархүү, Батжаргал, Маэда нар орчин үеийн Монгол хууль зүйн баримтыг BERT загвараар ангилах (classification) туршилт хийсэн [8]. Дараагийн судалгаанд Монголын хуульчийн шалгалтын иргэний эрх зүйн 829 асуултаар байгалийн хэлний логик хамаарлын (natural language inference, NLI) өгөгдөл байгуулж, хэд хэдэн Трансформер загварыг үнэлсэн [9]. Дээрх судалгаанууд нь Монгол хэлний хууль зүйн текст дээр Трансформер болон машин сургалтын аргыг ашиглах боломжтойг харуулсан хэдий ч нийтлэгдсэн эрүүгийн шүүхийн шийдвэрээс мөнгөн дүн, нөхөн төлөлт, огноо болон хөдөлмөрийн шинжийг нэг тогтмол мөрөнд олборлох даалгаврыг шууд үнэлээгүй.

Арга зүй болон даалгаврын хувьд Хуан нарын Тайванийн зам тээврийн ослын 1,000 шийдвэрээс хохиролтой холбоотой 18 багана олборлосон хамгийн төстэй судалгаа байна [11]. Тэд том хэлний загвар, зааврын өөр хувилбар (prompt variants), QLoRA болон дүрэмд суурилсан (rule-based) олборлолтыг харьцуулан туршсан. Энэхүү судалгаа нь мөн мөнгөн дүнтэй утгыг ялгаж, бүтэцлэгдсэн гаралт (structured output) үүсгэх зорилготой боловч Монгол хэл, хөдөлмөрийн харилцаатай эрүүгийн хэрэг, богино тоон схем болон 27–31B хэмжээтэй загваруудыг хамарч байгаагаараа энэ ажлаас ялгаатай. Иймээс өгөгдөл, даалгавар болон үнэлгээний хэмжүүрийн ялгааг харгалзан өмнөх судалгааны үр дүнг энэ ажлын үзүүлэлттэй шууд эрэмбэлэн харьцуулаагүй. Том хэлний загвараар бүтэцлэгдсэн гаралт үүсгэх нь дээрх мэдээллийг нэг загварын хүрээнд боловсруулах боломж олгодог боловч гаралтын тогтвортой байдал нь нэмэлт асуудал үүсгэнэ. Ялангуяа урт шүүхийн шийдвэр дээр загвар зөв утгыг олсон ч баганын дарааллыг солих, нэмэлт тайлбар бичих, тоон утгын нэгжийг өөрчлөх эсвэл шаардлагагүй текст үүсгэх нь дараагийн өгөгдөл боловсруулах шатанд алдаа болдог. Иймээс зөвхөн утгын зөв байдлыг бус, бүтэцийн төсөө, бүх багана зөв тохирол болон мөнгөн дүнтэй холбоотой багануудын зөв байдлыг тусад нь үнэлэх шаардлагатай. Хуан нарын ажил [11] нь бүтэцлэгдсэн мэдээлэл олборлоход том хэлний загвар, зааврын хувилбар, QLoRA болон дүрэмд суурилсан аргыг харьцуулсан чухал жишээ юм. Мөн цөөн параметр шинэчлэх замаар загварыг тухайн даалгаварт тохируулах арга нь хязгаарлагдмал тооцооллын орчинд том загвар ашиглах практик боломжтойг харуулсан бөгөөд бүх параметрийг шинэчлэхгүйгээр хууль зүйн домэйнд дасан зохицох өмнөх судалгааны чиглэлтэй [3] нийцэж байна.

Монгол хэлний хувьд илүү төвөгтэй байж болно. Хууль зүйн салбарт зориулсан өгөгдөл, жишиг үнэлгээний сан (benchmark) болон урьдчилан сургасан тусгай хэлний загвар цөөн тул англи, хятад зэрэг өгөгдөл ихтэй хэл дээр боловсруулсан аргыг шууд шилжүүлэх боломж хязгаарлагдана. Халтархүү нарын ангилал болон NLI судалгаанууд [8, 9] нь Трансформер загварууд Монгол хууль зүйн текст дээр ажиллах боломжтойг харуулсан боловч баримтын түвшний (document-level) бүтэцлэгдсэн гаралт үүсгэх үед урт эх, олон утгатай тоон дурдалт, хууль зүйн нэр томьёоны хэлбэлзэл болон гаралтын хатуу формат зэрэг нэмэлт шаардлага үүснэ. Иймээс Монгол шүүхийн шийдвэр дээрх бүтэцлэгдсэн мэдээлэл олборлолтыг тусдаа даалгавар болгон үнэлэх нь өгөгдөл олборлох судалгааны чиглэл гэж үзэж болно. Дээрх судалгаануудыг нэгтгэн авч үзвэл Монгол хэл дээрх хууль зүйн текстэд машин сургалт болон Трансформер загварыг ашиглах суурь бүрдсэн боловч шүүхийн шийдвэрээс урьдчилан тогтоосон олон баганатай гаралтыг цөөн параметр шинэчлэх LLM сургалтаар үүсгэх даалгавар хязгаарлагдмал судлагдсан байна. 2026 онд шалгасан нийтэд нээлттэй бүтээлүүдийн хүрээнд энэхүү даалгаврыг шууд үнэлсэн өмнөх ажил илрээгүй.

2 Өгөгдөл ба гаралтын бүтэц

2.1 Эх сурвалж

Энэхүү судалгаанд Шүүхийн шийдвэрийн цахим сан (https://shuukh.mn/) дээрх эрүүгийн хэргийн анхан шатны шийдвэрийн хайлтаас бүрдсэн өгөгдлийг ашиглав [15]. Хадгалсан таталтын бүртгэлд 2019-01-01–2026-08-03-ны хугацаа, Эрүүгийн хуулийн 17.4.1, 17.4.2.1, 17.4.2.2, 17.4.3 зүйл, хэсэг болон “Хөдөлмөрийн” түлхүүр үгийг ашигласан. Нийт 69 API хуудасны давхардалгүй 681 ID-г индексийн 681 ID-тай тулгахад ижил гарсан. Текст ашиглах боломжгүй хоёр шийдвэрийн тусад нь хадгалж, үлдсэн 679 шийдвэрт текстэн багц (packet) бэлтгэсэн. Эдгээрээс цэвэрлэсэн бүртгэлтэй холбогдсон 657 жишээг QLoRA туршилтад ашиглаж, холбогдоогүй 22 багцийг туршилтаас хасав.

Оролтын өгөгдөл нь шийдвэрийн бүтэн кессийг боловсруулалтгүйгээр загварт өгсөн хэлбэр биш бөгөөд урьдчилан сонгосон догол мөрүүдээс бүрдэх текстэн багц юм. Багц бүр META мөр болон P001, P002 гэх мэт дугаарласан догол мөрүүдээс бүрдэнэ. Ийм бүтэц нь урт шийдвэрийг GPU санах ойд багтаах, олборлолтод хамаарах хэсгийг төвлөрүүлэх боломж бүрдүүлсэн. Гэсэн хэдий ч боловсруулалтын шатанд шаардлагатай мэдээлэл хасагдах эрсдэлтэй тул энэхүү судалгааны үр дүн эцсийн бүтээгдэхүүний түвшинд биш болно.

Шалгах өгөгдөлийн мэдээлэл алдагдахаас (data leakage) сэргийлэх зорилгоор эхлээд `underlying_event_group`, дараа нь `same_decision_cluster`, эцэст нь хэргийн ID-г ашиглан бүлэглэл үүсгэв. Санамсаргүй эх утга (seed) 20260921-ийг ашиглан өгөгдлийг сургалтын 500 жишээ (473 бүлэг), хөгжүүлэлтийн 59 жишээ (59 бүлэг), шалгалтын 98 жишээ (93 бүлэг) болгон хуваасан бөгөөд хадгалсан бүлгийн түлхүүрүүд хуваалтуудын хооронд давхацаагүй. Muse-ийн токенчиллоор (tokenizer) сургалтын жишээний медиан урт 4,204, 90-р перцентиль 4,790, хамгийн урт нь 8,171 токен байв. Ижил эхийг Gemma болон Qwen-ийн токенчиллоор хэмжихэд хамгийн урт дараалал тус тус 9,431 ба 10,027 токен болсон.

Хүлээгдэж буй гаралтыг цэвэрлэсэн бүртгэлд тулгуурлан үүсгэв. Мөнгөн дүнгийн хувьд хянасан утга хадгалагдсан тохиолдолд түүнийг давуу авч, байхгүй үед өмнөх олборлолтын утгыг ашигласан. Огнооны өдөр нь тодорхойгүй бол -1 гэж кодолсон. `review_status=independently_reviewed` тэмдэглэгээ сургалтын, хөгжүүлэлтийн, шалгалтын олонлогт тус тус 80, 4, 15 жишээнд, нийт 99 шүүхийн шийдвэрт байна. Гэвч уг датаг хүн болон opus 5 хамтарч хянасан, нэг жишээг хэдэн хүн давхар хянасан зэрэг олон дамжлага хийгээгүй тул эдгээрийг бүрэн хүний баталгаатай алдаагүй хийсэн гэж үзээгүй, харин ”reference_label” гэж нэрлэв.

2.2 M1 гаралтын бүтэц

Загварын гаралтыг тогтмол бүтэцтэй байлгахын тулд `M1` тэмдэглэгээ болон босоо зураасаар (pipe) тусгаарласан 13 баганатай нэг мөрийн схем ашиглав:

```
M1|CID|LOSS|RECOV|OUTST|AWARD|RSTAT|OEND|CRECV|DECIS|ORGVIC|EMPREL|JOBACC|CONF
```

Энэхүү богино схем нь JSON хэлбэрээр түлхүүр нэрийг давтан үүсгэх зардлыг бууруулж, гаралтыг дараагийн шатанд SQL хүснэгт эсвэл JSON бүртгэлд тогтмол дүрмээр хөрвүүлэх боломжтой. Мөнгөн дүнг бүх төгрөгөөр, огноог `YYYYMMDD` хэлбэрээр илэрхийлсэн. Мөнгө болон огнооны мэдээлэл байхгүй үед -1, логик (boolean) баганад үнэн бол 1, худал бол 0, тодорхойгүй бол 9 гэж кодлов. `RSTAT` нь тодорхойгүй 0, төлөөгүй 1, хэсэгчлэн 2, бүрэн 3 гэсэн утгатай. Энд `AWARD` нь шүүхээс гаргуулахаар шийдвэрлэсэн дүн бөгөөд бодитоор төлөгдсөн `RECOV` болон шийдвэрийн өдрийн `OUTST`-оос утга нь ялгаатай.

Хүснэгт 4-ээс харахад нэг шийдвэрийн дотор 4.714.432 төгрөгийн нийт хохирол, 2.000.000 төгрөгийн өмнөх төлөлт, 2.714.432 төгрөгийн үлдэгдэл болон шүүхээс гаргуулах 2.714.432 төгрөгийн дүн зэрэгцэн дурдагдсан байна. Ийм тохиолдолд зөвхөн тоон утгыг таних бус, тухайн дүнгийн үүргийг өгүүлбэрийн утгаас ялгах шаардлагатай. Иймээс энэхүү даалгаварт хэлний загвар ашиглах гол үндэслэл нь семантикийн ялгалтыг автоматжуулахад оршино.

Багана	Жишээ (оролт)	Гаралт
CID Хэргийн дугаар	case_id=47180 decision_date=2020-07-22 META	47180
LOSS Шүүхийн тогтоосон нийт хохирол	…борлуулалтын орлогоос 4.714.432 төгрөгийг хувьдаа завшсан… P010	4714432
RECOV Шийдвэрээс өмнө бодитоор төлсөн	…үүнээс 2.000.000 төгрөгийн хохирлыг компанид төлж барагдуулсан байна. P014	2000000
OUTST Шийдвэрийн өдрийн үлдэгдэл	Иймээс үлдэгдэл 2.714.432 төгрөгийг [нэр хасав]-эс гаргуулах хүсэлтэй байна… P014	2714432
AWARD Шүүхээс гаргуулахаар шийдвэрлэсэн дүн	…шүүгдэгч [нэр хасав]-эс 2.714.432 төгрөг гаргуулж хохирогч [нэр хасав]-т олгосугай. P040	2714432
RSTAT Төлөлтийн төлөв (0/1/2/3)	…2.000.000 төгрөгийн хохирлыг компанид төлж барагдуулсан… үлдэгдэл 2.714.432… (хэсэгчлэн) P014	2
OEND Гэмт үйлдэл дууссан огноо	…2019 оны 4 дүгээр сарын 12-ноос 2020 оны 4 дүгээр сарын 30-ны өдрийн хооронд… P010	20200430
CRECV Шүүх хэргийг хүлээн авсан огноо	…2020 оны 6 дугаар сарын 23-ны өдөр хүлээн авч хянан хэлэлцэв. P008	20200623
DECIS Шийдвэрийн огноо	2020 оны 07 сарын 22 өдөр P002	20200722
ORGVIC Хохирогч байгууллага эсэх	…ХХК-д борлуулагчаар ажиллаж байхдаа… P010	1
EMPREL Үйлдэгч тэр байгууллагын ажилтан эсэх	…ХХК-д борлуулагчаар ажиллаж байхдаа… P010	1
JOBACC Албан тушаалаар хөрөнгөд хандах эрхтэй эсэх	…ажиллаж байхдаа бараа бүртээгдэхүүн борлуулсан борлуулалтын орлогоос… P010	1
CONF Хүлээгдэж буй гаралтын итгэлийн түвшин (1–3)	Өмнөх олборлогчийн гаралт: extractor_confidence.	3

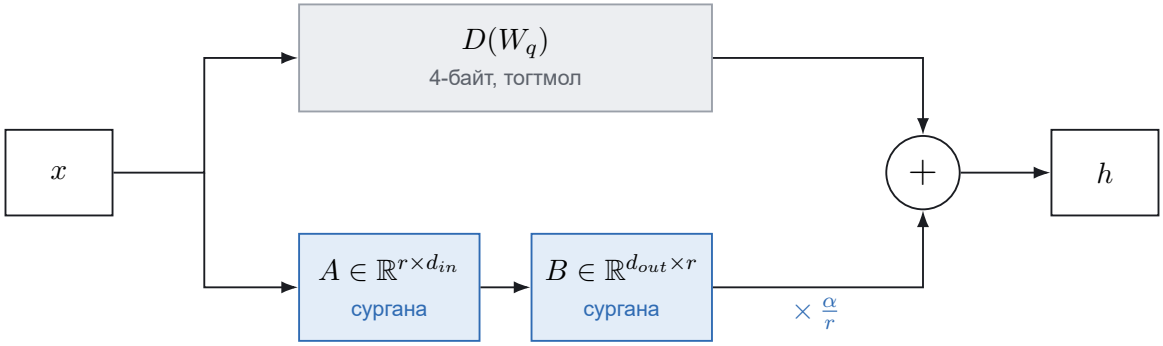
Хүснэгт 4: M1 баганууд ба олборлолтын жишээ (хөгжүүлэлтийн олонлог, хэрэг 47180). Улбар шар нь олборлох утга, цэнхэр талбар нь шүүхийн тогтоосон дүн, огноо. Эшлэлийг загварт өгсөн оролтын догол мөрөөс үгчлэн авсан (… нь хассан хэсэг, [нэр хасав] нь нууцалсан нэр). Энэ хэрэг дээр эцсийн сургасан хувилбарын зөв таамагласан багана: Muse QLoRA 13/13, Gemma QLoRA 13/13.

3 QLoRA сургалтын аргачлал

Энэ хэсэгт судалгаанд ашигласан QLoRA сургалтын аргачлал, промптын бүтэц болон GPU санах ойн (VRAM) хязгаарлалтад тохируулсан хэрэгжүүлэлтийг авч үзнэ. Суурь жингийн жижигрүүлсэн хувилбарыг W_q, сэргээх үйлдлийг (dequantization) D гэж тэмдэглэвэл тухайн шугаман давхаргын гаралтыг

$$h = D(W_q)x + \frac{\alpha}{r}BAx \tag{1}$$

гэж бичиж болно. Энд $A \in \mathbb{R}^{r\times d_{in}}$, $B \in \mathbb{R}^{d_{out}\times r}$ нь сургах (trainable) матрицууд бөгөөд бүх загварт $r = 8$, $\alpha = 8$ ашигласан. Суурь жинг тогтмол байлгаж, текстийн аттеншин (attention) болон MLP давхаргуудад LoRA жин оруулсан. Muse-ийн хадгалсан LoRA жинд 52,396,032, Gemma-д 61,214,720, Qwen-д 54,394,880 сургах параметртай. Ранк ижил боловч архитектур болон зорилтот модулийн хэмжээ өөр тул сургах параметрийн тоо ижил биш. Энэхүү QLoRA шинэчлэлтийн бүтцийг Зураг 1-т үзүүлэв.



Зураг 1: QLoRA шугаман давхаргын бүтэц. 4-байт хэлбэрээр жижигрүүлсэн суурь жин W_q тогтмол үлдэх бөгөөд зөвхөн бага ранктай A ба B матрицууд сургагдана. Туршилтад $r = 8$, $\alpha = 8$ ашиглав.

Сургалтын NLL-ыг (сөрөг үнэний хувь, negative log-likelihood) зөвхөн загварын хариуны зорилтот токен (target token) дээр тооцож, оролтын промпт хэсгийг хассан:

$$\mathcal{L} = -\frac{1}{|T|}\sum_{t\in T}\log p_{\theta,A,B}(y_t \mid x, y_{<t}), \tag{2}$$

энд T нь хариуны токены байрлал. промптын дугаарыг -100-аар маскалсан. Том үгийн сантай (vocabulary) загварт бүтэн дарааллын ложит (logits) үүсгэх зардлыг багасгахын тулд сүүлийн далд төлөвүүдийг (hidden states) `lm_head`-д оруулсан. Muse-д `logits_to_keep=128`, Gemma ба Qwen-д хариуны хяналттай токены (supervised tokens) тоо дээр нэгийг нэмсэн хэмжээг ашигласан. Зогсоох токеныг (stop token) сургалтын хариунд хамруулсан. Хариу богино боловч түүнд хүрэхийн тулд урт оролтын далд төлөвийг тооцож, градиентыг буцаан дамжуулах (backpropagation) шаардлага хэвээр үлдэнэ. LoRA шинэчлэлтийг бүтэн жинг шинэчлэх аргатай харьцуулбал ялгаа нь тодорхой ойлгогдоно. Ердийн шугаман давхаргад $W \in \mathbb{R}^{d_{out}\times d_{in}}$ жинг бүхэлд нь сургах үед

$$W^{(k+1)} = W^{(k)} - \eta\frac{\partial \mathcal{L}}{\partial W} \tag{3}$$

байна. Харин LoRA-д W тогтмол үлдэж, түүний өөрчлөлтийг бага ранктай хоёр матрицын үржвэрээр

$$\Delta W = \frac{\alpha}{r}BA \tag{4}$$

гэж төлөөлнө. Иймээс

$$h = (W + \Delta W)x = Wx + \frac{\alpha}{r}BAx \tag{5}$$

болох бөгөөд QLoRA-д суурь жинг 4-байт хэлбэрээр хадгалснаар

$$h = D(W_q)x + \frac{\alpha}{r}BAx \tag{6}$$

хэлбэрт шилжинэ. Эхний гишүүн нь тогтмол суурь загварын хувиргалт, хоёр дахь гишүүн нь сургалтаар өөрчлөгдөх LoRA нэмэлт юм. Бүтэн жинг сургах үед нэг шугаман давхаргад $d_{out}d_{in}$ параметр шинэчлэгдэх бол LoRA-д

$$N_{\text{LoRA}} = r(d_{in} + d_{out}) \tag{7}$$

параметр сургагдана. Иймээс сургах параметрийн бүтэн жинд харьцаа нь

$$\rho = \frac{r(d_{in} + d_{out})}{d_{in}d_{out}} \tag{8}$$

байна. Хэрэв $d_{in} = d_{out} = d$ гэж үзвэл

$$\rho = \frac{2r}{d}. \tag{9}$$

Жишээлбэл $d = 4096$, $r = 8$ үед $\rho \approx 0.0039$, буюу тухайн шугаман давхаргын бүтэн жингийн ойролцоогоор 0.39%-тай тэнцэх параметр сургагдана. Бодит загварт LoRA-г олон аттеншин болон MLP-д оруулдаг тул нийт сургах параметрийн тоо

$$N_{\text{train}} = \sum_{l=1}^{L} \sum_{m \in \mathcal{M}} r\left(d_{in}^{(l,m)} + d_{out}^{(l,m)}\right) \tag{10}$$

болно. Иймээс ижил $r = 8$ хэрэглэсэн ч Muse, Gemma, Qwen-ийн архитектур болон хэмжээнээс шалтгаалан нийт параметрийн тоо ялгаатай гарсан. QLoRA-ийн санах ойн гол хэмнэлт нь суурь жинг 4-байт хэлбэрээр хадгалахтай холбоотой. N параметрийг b бит нарийвчлалтай хадгалахад зөвхөн жинд шаардагдах онолын санах ойг $M_W \approx Nb/8$ байтаар илэрхийлж болно. Иймд 16-байт жинг 4-байт болгоход идеал нөхцөлд $M_4/M_{16} = 1/4$ болж, жингийн хадгалалтын хэмжээ дөрөв дахин буурна. Бодит хэрэгжүүлэлтэд жижигрүүллийн масштабын коэффициент, идэвхжил (activations), градиент болон түр тензор нэмэгдэх тул нийт VRAM яг дөрөв дахин буурахгүй. Гэсэн хэдий ч суурь жинг жижигрүүлж, зөвхөн LoRA параметрүүдийг сургах нь 27–31B хэмжээтэй загварыг 24 GB VRAM-д багтаах үндсэн нөхцөл болсон. NLL-ыг зөвхөн хариуны хэсэгт тооцож байгааг маскаар

$$m_t = \begin{cases} 1, & t \in T, \\ 0, & t \notin T \end{cases} \tag{11}$$

гэж тэмдэглэвэл

$$\mathcal{L}_{\text{NLL}} = -\frac{1}{\sum_{t=1}^{n} m_t} \sum_{t=1}^{n} m_t \log p(y_t \mid x, y_{<t}) \tag{12}$$

болно. Промптын токенд $m_t = 0$, зорилтот хариунд $m_t = 1$ тул NLL нь зөвхөн бүтэцлэгдсэн хариуг үүсгэх хэсэгт тооцогдоно. Хэрэгжүүлэлтэд үүнийг промптын дугаарыг -100 болгож NLL тооцооллоос хассан. Гэхдээ NLL-ыг зөвхөн хариуны токенд тооцох нь урт оролтын тооцооллыг арилгахгүй. Оролтын уртыг n_x, хариуны уртыг n_y гэвэл

$$n = n_x + n_y. \tag{13}$$

Трансформер-ийн аттеншин тооцооллын үндсэн хэмжээ ойролцоогоор

$$C_{\text{attn}} \propto n^2 d \tag{14}$$

хамааралтай. Энэ судалгаанд $n_x \gg n_y$ тул нийт тооцооллын гол зардлыг урт шүүхийн шийдвэрийн оролт үүсгэнэ. Иймээс хариу богино байсан ч түүнд хүрэхийн тулд урт оролтын далд төлөвийг бүхэлд

нь тооцох шаардлага хэвээр байна. Үгийн сангийн хэмжээг $|V|$, `lm_head`-д дамжуулах далд төлөвийн тоог k гэвэл гаралтын ложитын хэмжээ $k|V|$ байна. Бүх n байрлалд ложит үүсгэхэд

$$M_{\text{logit}} \propto n|V| \tag{15}$$

байх бол зөвхөн шаардлагатай сүүлийн k байрлалд тооцоход

$$M^{*}_{\text{logit}} \propto k|V|, \qquad k \ll n \tag{16}$$

болно. Иймээс `logits_to_keep` нь аттеншинын үндсэн тооцооллыг өөрчлөхгүй боловч шаардлагагүй байрлалын ложит үүсгэхээс зайлсхийж, `lm_head`-ийн түр санах ойн хэрэглээг бууруулсан.

3.1 Промптын бүтэц

Промптын заавар, кодчиллын дүрэм болон нэг зохиомол жишээг (one-shot example) гурван загварт ижил байдлаар ашиглаж, ярианы тэмдэглэгээг тухайн загварын `chat_template`-аар үүсгэв. Зааврын кессний хэсэгт M1 гаралтын 13 талбарыг тодорхойлж, дараагийн хэсэгт дутуу утга, андуурагдах мөнгөн дүн болон огноонд зориулсан дүрмийг оруулсан. Үүний дараа зохиомол жишээ болон гаралтыг нэг мөрөөр үүсгэх хязгаарлалтыг өгсөн бөгөөд Gemma, Qwen загваруудын бодох горимыг (thinking mode) унтраасан. Ашигласан промптын бүтцийг Зураг 2-т үзүүлэв.

ЗААВАР

```
Та Монгол Улсын шүүхийн шийдвэрээс даатгалын судалгаанд зориулж 13 утга ялгана.
Гаралт: нэг мөр, M1| гэж эхэлж, |-ээр тусгаарласан 14 талбартай.
M1|CID|LOSS|RECOV|OUTST|AWARD|RSTAT|OEND|CRECV|DECIS|ORGVIC|EMPREL|JOBACC|CONF
```

CID нь хэргийн дугаар; LOSS, RECOV, OUTST, AWARD нь ялгаатай утгатай мөнгөн дүн; OEND, CRECV, DECIS нь ялгаатай огноо; ORGVIC, EMPREL, JOBACC нь логик шинж; CONF нь кессийн итгэлийн түвшин.

ДҮРЭМ

Мэдээлэл байхгүй үед мөнгө, огноонд `-1`, boolean талбарт `9`, RSTAT-д `0` хэрэглэнэ. Шүүхээс гаргуулахаар тогтоосон AWARD дүнг бодитоор төлөгдсөн RECOV гэж үзэхгүй. Огноог зөвхөн `YYYYMMDD` хэлбэрээр гаргана. CRECV нь шүүх хүлээн авсан огноо бөгөөд прокурор хүлээн авсан огноотой андуурахгүй. кессэд төлөөгүй гэж тодорхой бичсэн бол `RECOV=0, RSTAT=1`; харин мэдээлэлгүй бол `RECOV=-1, RSTAT=0`.

НЭГ ЖИШЭЭ

```
META: case_id=900001 decision_date=2025-04-08
P004: ... нийт 5,940,000 төгрөгийн хохирол учруулсан ...
P019: ... шүүх хуралдаан гарахаас өмнө 1,500,000 төгрөгийг төлсөн ...
P041: ТОГТООХ нь: ... үлдэгдэл 4,440,000 төгрөгийг гаргуулж хохирогчид олгосугай ...
Гаралт: M1|900001|5940000|1500000|4440000|4440000|2|20240720|20250214|20250408|1|1|1|3
```

БОДОХ ЗАРЧИМ

Бодох (thinking) 2–3 өгүүлбэрээс хэтрэхгүй. Хувилбар жагсаахгүй, урт текст үүсгэхгүй. Тодорхойгүй бол дээрх дүрмийн дагуу `-1 / 9 / 0`-оос сонгож, дараа нь M1 мөрийг шууд гаргана.

ГАРАЛТЫН ФОРМАТ

```
Muse-Glimmer-30B: ...assistant M1|...|3
Gemma-4 31B: ...model ... M1|...|3
Qwen3.8-27B: ...assistant ... M1|...|3
```

Саарал хэсэг нь промптд орно; өнгөөр ялгасан M1 хэсэг нь сургалтын NLL тооцох болон QLoRA-ийн дараа загварын өөрөө үүсгэх хэсгийг илэрхийлнэ.

Зураг 2: Промптын бүтэц. Дээд хэсгүүд нэг промптд дараалан орж, бүх загвар, бүх туршилтад ижил; араас нь текст барц (META + P001...) залгана. Muse-ийн суурь үнэлгээнд л хариуны эхний оролтод залгаж механизиар шийдсэн; Gemma, Qwen-ийн суурь болон бүх QLoRA үнэлгээнд механизиар шийдээгүй. Хэсгүүдийг ялган үзүүлэх санааг Хуан нарын JURISIN хувилбараас авч өөрийн даалгаварт тохируулсан [12].

Зураг 2-т үзүүлсэн промптын гол онцлог нь LOSS, RECOV, OUTST, AWARD багануудын утгыг тусад нь тодорхойлсон явдал юм. Тухайлбал, шүүхээс гаргуулахаар тогтоосон дүнг бодитоор төлөгдсөн гэж үзэхгүй, RECOV болон AWARD-ийг хооронд нь хуулбарлахгүй байх дүрмийг тодорхой өгсөн. Мөн мэдээлэл байхгүй үед мөнгө болон огноонд -1, boolean баганад 9, RSTAT-д 0 буцаахаар тохируулсан. Ингэснээр кессэд нотолгоо байхгүй үед боломжит утга зохиохоос илүү тодорхойгүй төлөв сонгох нөхцөлийг бүрдүүлсэн.

3.2 Сургалтын тохиргоо ба санах ойн оновчлол

Muse-Glimmer-30B нь өөрчилсөн Трансформер архитектуртай хараа-хэлний загвар (vision-language model) бөгөөд энэхүү судалгаанд зөвхөн текст боловсруулах аргыг ашиглав. Текстийн хэсэг нь 52 давхарга, 202,048 токентой үгийн сан, 32 асуулгын (query) болон 2 түлхүүр/утга (key/value) толгойтой (heads). Туршилтыг нэг RTX 3090 24 GB төхөөрөмж дээр гүйцэтгэхийн тулд NF4 болон давхар жижигрүүлсэн (double quantization), BF16 тооцоолол, зургийн хэсгийг (vision encoder) хасах, тогтмол оролтын эмбэдингийг (embedding) CPU дээр байрлуулах, завсрын төлөвийг дахин тооцоолох, завсрын тензорийг (intermediate tensors) CPU руу шилжүүлэх, санах ой хэмнэх SDPA хэрэгжүүлэлт сонгох, зөвхөн хариуны төгсгөлийн ложит дээр NLL тооцох зэрэг аргыг хослуулсан. PyTorch SDPA нь оролт, төхөөрөмж болон тооцооллын хэрэгжүүлэлтийн нөхцлөөс хамааран өөр хэрэгжүүлэлт сонгодог тул энэхүү Windows орчинд ашигласан хэрэгжүүлэлтийг FlashAttention гэж нэрлээгүй [4].

Хүснэгт 5: Muse-ийн сургалтын тохиргоо.

Үзүүлэлт	Утга
GPU, орчин	RTX 3090 24 GB; Windows; GPU-ийн чадлын дээд хязгаар 360 W
Жижигрүүлэл, тооцоолол	4-байт NF4, давхар жижигрүүлсэн, BF16
LoRA	$r = 8$, $\alpha = 8$, дропоут (dropout) 0, биас (bias) сургахгүй
Зорилтот модулиуд	`q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj`
Микробач (Microbatch)	1 шинэчлэлт нь; 16 Микробач тутам шинэчлэлт
Сургалт	2 эпоч (epoch); бодит 64 оновчлолын алхам (optimizer step)
Сурах хурд (Learning rate)	2×10^{-4}; шугаман бууралт (decay); сурах хурдыг аажмаар нэмэгдүүлэх эхний 2 алхам (warmup)
Оптимизаци хийх алгоритм	`adamw_bnb_8bit`
Дарааллын дээд урт (max sequence length)	9,216 токен; сургалтын жишээний дээд урт 8,171
Сангууд	PyTorch 2.11.0+cu128, Transformers 5.17.0, PEFT 0.21.0, bitsandbytes 0.50.2

Сургалтын логийн үр дүнгээр Muse-ийн `train_runtime` ойролцоогоор 16,870 секунд буюу 4.69 цаг байв. Энэ нь амжилттай дууссан бүтэн сургалтын хугацаа бөгөөд урьдчилсан алдаа засвар, загвар татах болон дахин эхлүүлсэн туршилтын хугацааг агуулаагүй. Тусгаарласан урт жишээний туршилтад 8,171 токен дээр 20.68 GiB хамгийн их хуваарилсан (peak allocated) VRAM, 9.5 секунд форвард (forward pass), 28.7 секунд буцаах (backward pass) хурд хэмжигдсэн.

Gemma болон Qwen загваруудад мөн NF4, давхар жижигрүүлсэн, BF16, $r = \alpha = 8$, дропоут 0, нэг жишээтэй Микробач, 16 алхмын нийлбэр, хоёр эпоч (бүх өгөгдөл дээр үндэслэн моделийг шинэчилсэн циклийн тоо), 2×10^{-4} эхний сурах хурд, сурах хурдыг аажмаар нэмэгдүүлэх эхний хоёр алхам болон 20260921 санамсаргүй эх утгыг ижил ашиглав. Аль алинд 64 алхам гүйцэтгэсэн. Gemma-ийн оролтын эмбэдинг болон гаралтын давхарга нэг жин хуваалцдаг (tied weights) тул уг матрицыг CPU-ийн ердийн санах ойд байрлуулж, эмбэдингийн хайлтыг CPU дээр, гаралтын давхаргын матриц үржвэрийг GPU руу 16,384 мөрөөр хэсэгчлэн дамжуулан тооцсон. Мөн 6,144-өөс урт дарааллын MLP тооцоог дөрвөн хэсэгт хувааж, завсрын төлөвийг дахин тооцох аргыг (recomputation) ашигласнаар 9,431 токентой жишээг таслахгүйгээр сургах боломж бүрдсэн.

Qwen загварын хувьд тогтмол эмбэдинг-ийг CPU руу шилжүүлж, ижил уртын босгоос дээш MLP болон Gated DeltaNet толгойн тооцоог тус бүр дөрвөн хэсэгт хуваав. Тус загварын 48 шугаман

аттеншин давхарга Transformers-ийн PyTorch хэрэгжүүлэлтээр, 16 бүрэн аттеншин давхарга санах ой хэмнэх SDPA-аар ажилласан. LoRA-ийн зорилтот модульд ердийн аттеншин болон MLP проекцоос гадна `in_proj_qkv`, `in_proj_z`, `out_proj`-ийг хамруулсан.

Хүснэгт 6: Gemma ба Qwen-ийн нэмэлт тохиргоо, бүтэн сургалтын хэмжилт.

Үзүүлэлт	Gemma-4 31B	Qwen3.8-27B
Текстийн давхарга	60	64
Сургах LoRA параметр	61,214,720	54,394,880
Сургалтын хамгийн урт дараалал	9,431	10,027
Сургалтын хугацаа (цаг)	9.34	15.66
CUDA хамгийн их хуваарилсан VRAM (GiB)	20.15	19.98
CUDA хамгийн их нөөцөлсөн (peak reserved) VRAM (GiB)	21.96	21.76
Хамгийн их WDDM нийт VRAM (GiB)	22.27	22.06

Хүснэгт 5 болон Хүснэгт 6-ээс харахад гурван загварын сургалтыг 24 GB GPU-ийн өөрийн VRAM-ийн хүрээнд дуусгасан. CPU руу шилжүүлсэн завсрын төлөвүүд системийн RAM ашигладаг тул илүү гарсан хэмжээг VRAM-аас албадан RAM руу хийсэн хэмжээ гэж үзээгүй. Гэсэн хэдий ч дээрх санах ойн шийдэл бүрийн дан нөлөөг тусад нь хэмжсэн бүрэн туршилт хийгдээгүй тул GPU санах ойд багтсан байдлыг нийт хэрэгжүүлэлтийн үр дүн гэж тайлбарлав.

4 Үнэлгээний аргачлал

4.1 Сургалтын хувилбар сонгох

Сургалтын хувилбарыг сонгохдоо 20, 30, 45-р оновчлолын алгоритмын алхмын хадгалсан төлөв болон эцсийн 64-р алхмын хувилбарыг 59 хөгжүүлэлтийн жишээн дээр үнэлэв. Шалгуурт формат зөв мөрийн хувь, 13 баганын зөв таамагласан хувь, бүх 13 багана зөв мөрийн хувийг дарааллаар ашигласан. Gemma болон Qwen-ийн хувьд эдгээр үзүүлэлт тэнцсэн тохиолдолд утгын эргэлзээтэй (warning) цөөн, дараа нь хожуу алхмыг сонгох нэмэлт дүрэм хэрэглэв. Энэхүү шалгууруар гурван загварт эцсийн 64-р алхмын хувилбар сонгогдсон.

Хүснэгт 7: Хөгжүүлэлтийн олонлогийн үр дүн ($N = 59$). Эхний гурван хэмжүүрийг хувиар, утгын эргэлзээтэй мөрийг тоогоор үзүүлэв. † нь сонгосон сургалтын төлөв. Qwen-ийн 45 болон 64-р алхмын хадгалсан үнэлгээг хамтатган үзүүлэв.

Загвар	Алхам	Формат зөв	13 багана	Бүх мөр	Эргэлзээтэй
Muse-Glimmer-30B	20	96.6	80.3	15.3	12
	30	100.0	80.8	20.3	6
	45	100.0	81.2	23.7	6
	64†	100.0	82.5	23.7	10
Gemma-4 31B	20	98.3	81.7	18.6	1
	30	100.0	81.5	20.3	6
	45	100.0	82.8	23.7	6
	64†	100.0	83.2	25.4	3
Qwen3.8-27B	20	100.0	84.5	27.1	4
	30	100.0	84.7	30.5	4
	45	100.0	86.0	30.5	5
	64†	100.0	86.6	33.9	5

Хүснэгт 7-ээс харахад Muse-гийн 64-р алхмын хувилбар 45-р алхамтай бүх мөрийн үзүүлэлтээр тэнцсэн боловч баганын дунджаар 1.3 нэгж хувиар өндөр байв. Gemma-гийн 64-р алхмын

хувилбар баганын түвшинд 83.2%, бүх мөрийн түвшинд 25.4%үзүүлэлттэй гарсан. Qwen-гийн 64-р алхмын хувилбар 13 баганын зөв таамагласан хувийг 86.6%, бүх мөрийн зөв хувийг 33.9%болгон өсгөсөн тул ижил сонголтын дүрмээр 64-р алхмыг эцсийн хувилбараар сонгов. Гэсэн хэдий ч Muse-д анхааруулгын тоо 45-р алхмаас 64-р алхамд 6-аас 10 болж өссөн тул тухайн алхам дахь хадгалагдсан модел (checkpoint) сонголтыг зөвхөн нэг хэмжүүрийн өсөлт гэж тайлбарлаагүй.

4.2 Харьцуулалт

Энэхүү судалгаанд суурь загвар (pre-trained) гэж тухайн даалгаврын QLoRA сургалтаас өмнөх хувилбарыг нэрлэв. Татаж авсан загварууд өмнө нь зааварт тохируулан сургасан (instruction tuning) байж болох тул зөвхөн урьдчилсан сургалт (pre-training) хийсэн загвар гэж үзээгүй. Бүх харьцуулалтад ижил хэргийн ID болон ижил баталгаа өндөр ялгасан бүхий 98 шалгалтын жишээг ашигласан. Muse-ийн суурь хувилбарт `to=user<|message|>M1|` эхлэл өгсөн бол сургасан хувилбарт эхлэл тулгаагүй. Харин Gemma болон Qwen-д суурь, сургасан аль алинд гаралтын эхлэл тулгаагүй. Иймээс Muse-ийн өмнө/дараах харьцуулалт нь LoRA жингийн нөлөөнөөс гадна ажиллуулах горимын ялгааг давхар агуулна.

Үүсгэлтийг (generation) алхам бүрд хамгийн өндөр магадлалтай токеныг сонгох (greedy) горимоор гүйцэтгэж, Muse-д `max_new_tokens=96`, Gemma болон Qwen-д 192 токены хязгаар ашиглав. промптын агуулга ижил боловч чатын загвар, токенчилол болон гаралтын уртын хязгаар загвар бүрт ялгаатай. Иймээс хугацаа болон гаралтын токены тоог архитектурын цэвэр хурдыг шууд харьцуулсан хэмжүүр гэж үзээгүй.

Загваруудын гүйцэтгэлийг үнэлэхдээ баганын түвшний зөв таамагласан хувийг

$$A_{field} = \frac{1}{13N} \sum_{i=1}^{N} \sum_{j=1}^{13} \mathbf{1}[\hat{y}_{ij} = y_{ij}] \tag{17}$$

гэж тооцсон. Бүх 13 багана зэрэг таарсан тохиолдлыг бүх мөр зөв гэж үзсэн. Мөн LOSS, RECOV, OUTST, AWARD дөрвөн мөнгөн дүнтэй баганын дундаж болон дөрвүүлээ зэрэг зөв гарсан мөрийн хувийг тусад нь тооцсон. Форматын үзүүлэлт нь гаралт задлагчийн (parser) олсон M1 мөр HARD алдаагүй эсэхийг хэмжинэ. Хоёр хувилбарын ялгааны тодорхойгүй байдлыг 93 шалгалтын бүлгээр хослуулсан бүлгийн бутстрэп (bootstrap) аргаар 10,000 удаа дахин түүвэрлэж (resampling), 95%-ийн итгэх интервал тооцсон. Энэ интервал нь шалгалтын түүврийн хэлбэлзлийг хэмжих бөгөөд баталгаа өндөр ялгасаны алдаа, өөр сургалтын санамсаргүй эх утгын хэлбэлзлийг агуулахгүй.

4.3 Бусад зүйл дээрх шалгалт ба хариуг нэгтгэх арга

17.4-ийн шийдвэрээр сургасан загварууд бусад төрлийн шийдвэрээс мэдээлэл гаргаж чадах эсэхийг шалгахын тулд 10 бүлгийн 49 шийдвэрээр нэмэлт туршилт хийв. 17.3, 17.1, 17.8, 17.5, 23.2, 22.8, 26.x, 22.10, 17.11 бүлэг тус бүрд 5, 18.15-д 4 шийдвэр орсон. Эдгээрийн таних дугаар үндсэн 657 жишээнийхтэй давхцаагүй. Зарим шийдвэр хэд хэдэн зүйлээр хамт зүйлчлэгдсэн тул бүлгийн нэр нь тухайн шийдвэр зөвхөн нэг зүйлд хамаарна гэсэн утгагүй. Энэ 49 шийдвэрээр нэмэлт сургалт хийгээгүй бөгөөд хөгжүүлэлтийн олонлогоор сонгосон гурван QLoRA хувилбарын хадгалсан гаралтыг үнэлэв.

Үнэлгээнд ашигласан 49 шийдвэрийн гаралтыг хүн болон Opus 5.5 загвараар давхар хянасан. CID нь оролтоос хуулдаг таних дугаар, CONF нь энэ гаралтын бүх мөрөнд 1 байсан тул хоёуланг нь үндсэн хэмжүүрээс хасав. Ийнхүү LOSS-оос JOBACC хүртэлх 11 баганын нийт $49 \times 11 = 539$ утгыг харьцуулж, нэг шийдвэрийн бүх 11 утга зөв бол тухайн мөрийг бүтэн зөв гэж тооцов. Мөнгөн дүнтэй, огноотой болон төлөв, ангиллын баганаудыг, RSTAT болон ORGVIC/EMPREL/JOBACC дөрвөн баганын дунджийг тусад нь гаргав. Мөнгө, огноо тодорхойгүй үед -1, логик баганад 9, төлөлтийн төлөвт 0 гэсэн тэмдэглэгээг мөн үнэлгээнд оруулсан. Үндсэн 98 шийдвэр болон нэмэлт 49 шийдвэрийн үр дүнг тусад нь тайлагнав.

Гурван загварын хариуг (ensemble) багана тус бүрээр олонхын саналаар (majority voting) нэгтгэв. Хоёр буюу гурван загвар ижил утга гаргасан бол тэр утгыг сонгосон. Гурвуулаа өөр утга гаргасан үед тухайн баганад өмнөх 59 хөгжүүлэлтийн жишээн дээр хамгийн сайн ажилласан загварыг сонгож, тэнцвэл хөгжүүлэлтийн 13 баганын нийт үзүүлэлтээр эрэмбэлэв. Энэ дүрмийг 98 болон 49 шийдвэрт ижил хэрэглэсэн. Мөн гурван загварын аль нэг нь зөв утга гаргасан бүх тохиолдлыг зөв гэж тооцсон дээд хязгаарыг (oracle upper bound) гаргав. Энэ нь зөв хариуг мэдэж байж сонгодог тооцоо бөгөөд бодит хэрэглээнд ажиллах нэгтгэх арга биш юм.

Нэмэлт шалгалтад нэгтгэсэн хариу болон загвар тус бүрийн 11 баганын ялгааг 49 шийдвэрээр хослуулан бутстрэп аргаар дахин түүвэрлэж тооцов. Нэг шийдвэрийн 11 баганыг хамтад нь авч, 10,000 давталт дээр 95%-ийн итгэх интервал тооцсон. Үндсэн 98 шийдвэрийн хувьд өмнөх 93 бүлгийн бутстрэп тооцоог ашиглав.

5 Үр дүн

5.1 Muse-ийн суурь загвартай хийсэн харьцуулалт

Энэ хэсэгт QLoRA сургалтын дараах үр дүнг суурь хувилбартай харьцуулан авч үзэв. Muse-ийн сургасан хувилбарын 1,274 баганын 1,125 нь баталгаа өндөр ялгасантай таарч, 98 мөрийн 33 нь бүхдээ зөв гарсан. Мөнгөн дүнтэй багануудын 392 утгаас 321 нь зөв гаргасан, дөрвөн мөнгөн дүнтэй багана зэрэг 65 мөрт таарсан. Харин CID болон CONF-ийг хасахад 11 баганын зөв хувь 86.2%байсан нь нийт 88.3%-ийн үзүүлэлтийг зөвхөн хохирол, төлөлт олборлох чадвар гэж тайлбарлах боломжгүйг харуулж байна.

Хүснэгт 8: Muse-ийн ижил 98 шалгалтын жишээн дээрх үр дүн. Өөрчлөлт нь хувиар.

Хэмжүүр	Суурь	QLoRA	Өөрчлөлт
Формат зөв мөр (%)	83.7	100.0	+16.3
13 баганын зөв таамагласан хувь (%)	69.0	88.3	+19.3
Бүх багана зөв мөрийн хувь (%)	2.0	33.7	+31.6
Мөнгөн дүнтэй багануудын үнэн таамагласан хувь (%)	51.0	81.9	+30.9
Мөнгөн дүнтэй багануудын зэрэг зөв таасан хувь (%)	18.4	66.3	+48.0
CID, CONF-гүй 11 багана (%)	64.4	86.2	+21.8
Эргэлзээтэй: `XRO_mismatch` (тоо)	17	7	–
Үүсгэлтийн медиан (секунд)	10.3	18.1	–
Гаралтын токены медиан	37	43	–
Хамгийн өндөр VRAM хэрэглээ (GiB)	20.04	21.47	–

Хүснэгт 8-ээс харахад Muse-ийн QLoRA хувилбарын формат зөв мөрийн хувь 100%болж, 13 баганын зөв таамагласан хувь суурь хувилбараас 19.3 нэгж хувиар нэмэгдсэн. бүх мөрийн зөв хувь 2.0%-оос 33.7%, мөнгөн дүнтэй дөрвөн баганын зөв хувь 51.0%-оос 81.9%болж өсөв. Бүлгийн бутстрэп шинжилгээгээр 13 баганын өсөлтийн 95%хувийн итгэх интервал нь $[15.8, 23.0]$, бүх мөрд итгэх интервал $[22.4, 41.2]$, мөнгөн дүнгийн итгэх интервал $[23.9, 37.9]$ байв. Эдгээр үр дүн нь сонгосон шалгалтын олонлог болон баталгаа өндөр ялгасаны хүрээнд QLoRA сургалтын дараа олборлолтын чанар мэдэгдэхүйц сайжирсныг харуулж байна.

Гэсэн хэдий ч Muse-ийн QLoRA хувилбарын медиан үүсгэлтийн хугацаа 10.3-аас 18.1 секунд болж нэмэгдсэн. Суурь хувилбарт эхлэлийн зургаан токеныг урьдчилан өгсөн бол сургасан хувилбар тэдгээрийг өөрөө үүсгэсэн бөгөөд медиан гаралт зургаан токеноор урт байв. Иймээс хугацааны ялгааг LoRA адаптерийн дан нөлөө гэж үзэх боломжгүй. Энэхүү туршилтын гол хэмжигдсэн үр ашиг нь олборлолтын чанарын өсөлтөд байна.

5.2 Загваруудын үр дүн

Хүснэгт 9-д гурван загварын суурь болон QLoRA хувилбарын шалгалтын үр дүнг багана тус бүрээр харьцуулан үзүүлэв. Ингэснээр нийт дундаж үзүүлэлтийн цаана аль талбарт алдаа төвлөрч байгааг нарийвчлан үнэлэх боломж бүрдсэн.

Хүснэгт 9: Суурь ба QLoRA-аар сургасан (хөгжүүлэлтийн олонлогоор сонгосон хувилбар) загваруудын шалгалтын олонлог ($N = 98$) дээрх зөв таамагласан хувь (%). Суурь Gemma нь урт промпт дээр ”—S-S-S-S-S…” гэсэн алдаатай гаралт буцааж байсан; 0 нь тухайн мөрд зөв M1 гаралт үүсгээгүйг заана. Qwen-ийн QLoRA баганад хөгжүүлэлтийн олонлогоор сонгосон 64-р алхмын эцсийн шалгалтын үр дүнг үзүүлэв.

		Muse-Glimmer-30B		Gemma-4 31B		Qwen3.8-27B	
Баганын төрөл	Багана	Суурь	QLoRA	Суурь	QLoRA	Суурь	QLoRA
Мөнгөн дүн	LOSS	75.5	88.8	0.0	90.8	85.7	91.8
	RECOV	26.5	70.4	0.0	80.6	28.6	80.6
	OUTST	36.7	78.6	0.0	84.7	37.8	86.7
	AWARD	65.3	89.8	0.0	87.8	75.5	90.8
	Дундаж	51.0	81.9	0.0	86.0	56.9	87.5
Огноо	OEND	59.2	67.3	0.0	73.5	71.4	81.6
	CRECV	64.3	68.4	0.0	75.5	77.6	70.4
	DECIS	100.0	100.0	0.0	100.0	100.0	100.0
	Дундаж	74.5	78.6	0.0	83.0	83.0	84.0
Төлөв, ангилал	RSTAT	32.7	91.8	0.0	92.9	37.8	93.9
	ORGVIC	85.7	96.9	0.0	95.9	91.8	93.9
	EMPREL	80.6	98.0	0.0	94.9	88.8	94.9
	JOBACC	81.6	98.0	0.0	94.9	90.8	94.9
	CONF	88.8	100.0	0.0	100.0	93.9	100.0
	Дундаж	73.9	96.9	0.0	95.7	80.6	95.5
Таних	CID	100.0	100.0	0.0	100.0	100.0	100.0
Багануудын дундаж		69.0	88.3	0.0	90.1	75.4	90.7
Бүх мөр зөв		2.0	33.7	0.0	41.8	9.2	41.8
Формат зөв		83.7	100.0	0.0	100.0	100.0	100.0

Хүснэгт 9-ийн үр дүнгээс Gemma-ийн QLoRA хувилбарт 1,274 утгаас 1,148 нь, 98 мөрөөс 41 нь бүрэн зөв таарсан байна. Мөнгөн дүнтэй багануудын 392 утгаас 337 буюу 86.0%зөв, дөрвөн дүн зэрэг зөв мөр 75 буюу 76.5%байв. Muse-ийн мөнгөн дүнгийн дундаж 81.9%, дөрвөн дүн зэрэг зөв мөр 66.3%байсан. Баганын түвшинд Gemma RECOV дээр 80.6%буюу Muse-ээс 10.2 нэгж хувиар өндөр, AWARD дээр 87.8%буюу 2.0 нэгж хувиар бага гарсан.

Gemma болон Muse-ийн сургасан хувилбарын 13 баганын дундаж ялгаа $+1.8\%$, хослуулсан бүлгийн бутстрэпийн 95%-ийн итгэх интервал $[-0.4, 3.9]$ байв. бүх мөрийн ялгаа $+8.2\%$, итгэх интервал $[-2.1, 18.6]$ гарсан. Эдгээр итгэх интервал тэгийг агуулж байгаа тул энэ түүврийн хүрээнд нийт үзүүлэлтээр нэг загвар нөгөөгөөсөө тогтвортой давуу гэж дүгнэх үндэслэл хангалтгүй байна. Харин мөнгөөрх дөрвөн багана зэрэг зөв мөрийн ялгаа $+10.2\%$, итгэх интервал $[1.0, 19.2]$ байв. Гэсэн хэдий ч энэ нь нэг санамсаргүй эх утга, нэг шалгалтын өгөгдөл болон олон хэмжүүрийн нэгэнд үндэслэсэн үр дүн тул ерөнхий давуу байдлын баталгаа гэж өргөжүүлэн тайлбарлаагүй.

Gemma-ийн суурь үнэлгээнд 98 хариу бүгд 192 токены хязгаарт хүрч зогссон бөгөөд 97-д M1 мөр олдоогүй, нэгэнд баганын тоо буруу байв. Ийм гаралтыг үнэлгээний дүрмээр бүх баганад буруу гэж тооцсон тул Хүснэгт 9-д 0%гарсан. Гэвч энэхүү тэг оноо нь зөвхөн ашигласан промпт, жижигрүүлэл болон үүсгэлтийн горимд олборлолт амжилтгүй байсныг илэрхийлэх бөгөөд загварын хууль зүйн ойлголт бүхдээ байхгүйг нотлохгүй.

Qwen3.8-27B-ийн QLoRA үр дүн. Qwen-ийн суурь хувилбар баганын түвшинд 75.4%, бүх мөрөөр 9.2%, мөнгөөрх дөрвөн баганад 56.9%, форматад 100.0%зөв гарсан. Харин хөгжүүлэлтийн олонлогоор сонгосон 64-р алхмын QLoRA хувилбарын харгалзах үзүүлэлт 90.7%, 41.8%, 87.5%, 100.0%байв. Суурь хувилбартай харьцуулахад 13 баганын дундаж $+15.4$ хувь, бүх мөрийн зөв хувь $+32.7$ хувь, мөнгөн дүнгийн дөрвөн баганын дундаж $+30.6$ нэгж хувиар өссөн. 93 шалгалтын бүлгээр хийсэн хослуулсан бүлгийн бутстрэпийн 95%-ийн итгэх интервал эдгээр гурван хэмжүүрт тус тус $[12.3, 18.5]$, $[21.4, 43.8]$, $[24.0, 37.4]$ байв. мөнгөөрх дөрвөн багана зэрэг зөв мөрийн хувь 78.6%, CID ба CONF-ийг хассан 11 баганын зөв хувь 89.1%, утгын эргэлзээтэй мөрийн тоо 1 байлаа. Туршилтын үр дүнгээр Qwen-ийн QLoRA хувилбар суурь хувилбараасаа бүх нийлбэр хэмжүүрээр сайжирсан боловч энэхүү үр дүнг нэг санамсаргүй эх утга болон нэг шалгалтын өгөгдлийн хүрээнд тайлбарлав.

Хүснэгт 10: Шалгалтын олонлог дахь үүсгэлтийн хугацаа ба санах ой. Gemma-ийн суурь гаралт бүгд уртын хязгаарт тасарсан.

Хувилбар	Медиан (секунд)	Гаралтын токен[a]	Хамг.өндөр VRAM (GiB)
Muse суурь	10.3	37	20.04
Muse QLoRA	18.1	43	21.47
Gemma суурь	44.9	192	21.02
Gemma QLoRA	30.2	69	22.14
Qwen суурь	20.0	67	21.13
Qwen QLoRA	31.2	68.5	21.32

[a]Медиан; токенчилол өөр тул токены тоогоор нь загвар хооронд зөрүүг харьцуулах боломжгүй.

Хүснэгт 10-ээс харахад үүсгэлтийн хугацаа болон GPU санах ойн хэрэглээ загвар бүрт ялгаатай байна. Muse QLoRA-ийн хамгийн өндөр VRAM хэрэглээ 21.47 GiB, Gemma QLoRA-ийнх 22.14 GiB, Qwen QLoRA-ийнх 21.32 GiB байв. Qwen QLoRA-ийн медиан үүсгэлтийн хугацаа 31.2 секунд, гаралтын медиан урт 68.5 токен гарсан. Gemma-ийн QLoRA хувилбар суурь хувилбараасаа хурдан харагдаж байгаа боловч суурь гаралт бүр 192 токены дээд хязгаарт тасарсан тул уг зөрүүг архитектурын шууд хурдны давуу тал гэж тайлбарлаагүй. Үүнтэй адил Qwen-ийн хугацаанд токенчлогч, аттеншин бүтэц болон гаралтын уртын хам нөлөө агуулагдах тул архитектурын дан хурд гэж үзэх боломжгүй.

5.3 Загваруудын хариуг нэгтгэсэн үр дүн

Үндсэн 98 шийдвэр дээр олонхын саналаар нэгтгэхэд 13 баганын зөв хувь 91.7%, CID ба CONF-гүй 11 баганын зөв хувь 90.2% болсон (Хүснэгт 11). Qwen дангаараа ажилласантай харьцуулахад өсөлт нь тус тус 0.9 болон 1.1% байв. Бүх 13 баганыг зөв гаргасан мөр 41-ээс 46 болсон боловч энэ хэмжүүрийн ялгааны 95%-ийн итгэх интервал $[-3.0, 13.4]$ хувь буюу 0-ийг агуулсан. Мөнгөн дүнтэй багануудын үнэн таасан дундаж 87.5%-оос 88.5% болсон ч мөнгөн дүнтэй баганууд дээр зэрэг зөв мөрийн тоо 77/98 хэвээр байв.

Хүснэгт 11: Үндсэн 98 шийдвэр дээрх QLoRA загварууд болон нэгтгэсэн хариу. Баганын болон мөнгөн дүнгийн үзүүлэлтийг хувиар, зөв мөрийг тоогоор үзүүлэв.

Хувилбар	13 багана (%)	11 багана (%)	Бүтэн мөр (13)	Мөнгө (%)	4 мөнгө зэрэг
Muse	88.3	86.2	33/98	81.9	65/98
Gemma	90.1	88.3	41/98	86.0	75/98
Qwen	90.7	89.1	41/98	87.5	77/98
Нэгтгэсэн	91.7	90.2	46/98	88.5	77/98

5.4 Шүүхийн шийдвэрийн бүтэцийг өөрчилсөн робаст тест

Гурван загвар бүгд 49 шийдвэрт форматын шаардлага хангасан M1 мөр гаргасан. Хүн болон Opus 5.5-аар давхар хянасан кесстэй харьцуулахад 539 утгаас Muse 398, Gemma 391, Qwen 421-ийг зөв гаргав. Баганын дунджаар Qwen хамгийн өндөр байсан боловч бүх 11 баганыг зөв гаргасан мөрөөр Gemma 15/49, Muse болон Qwen тус бүр 13/49 байв. Иймээс баганын дундаж болон нэг шийдвэрийн хариу бүхэлдээ зөв байх үзүүлэлтүүд өөр эрэмбэ өгч байна.

Хүснэгт 12: Бусад зүйл ангийн 49 шийдвэрийн үр дүн. CID ба CONF-ийг хассан 11 баганаар үнэлэв.

Хувилбар	11 багана (%)	Бүтэн мөр (11)	Мөнгө (%)	4 мөнгө зэрэг	Огноо (%)	Төлөв, ангилал (%)
Muse	73.8	13/49	68.9	23/49	87.1	68.9
Gemma	72.5	15/49	61.7	18/49	84.4	74.5
Qwen	78.1	13/49	70.9	23/49	89.1	77.0
Нэгтгэсэн	77.4	14/49	69.9	23/49	90.5	75.0
Дээд хязгаар[a]	84.6	18/49	76.0	26/49	95.2	85.2

[a]Нэг мөрийн зөв утгууд өөр өөр загвараас ирж болно. Энэ нь бодитоор ажилласан дөрөв дэх загварын үр дүн биш.

Нэгтгэсэн хариу 539 утгаас 417-ийг зөв гаргаж, 77.4% болсон. Энэ нь Qwen-ийн 78.1%-аас 0.7 нэгж хувиар бага боловч зөрүүгийн итгэх интервал тэгийг агуулсан тул аль нэг нь давуу гэж энэ түүврээр тогтоох боломжгүй (Хүснэгт 13). Харин нэгтгэсэн хариуны огнооны дундаж 90.5% болж, гурван загварын тус тусын үзүүлэлтээс өндөр гарсан. Нийт 11 баганын дунджаар Qwen-ээс давсангүй ч зарим төрлийн талбарт нэгтгэх нь тус болж байна.

Хүснэгт 13: 49 шийдвэр дээрх 11 баганын үзүүлэлтийн ялгаа. Зөрүү болон интервалын нэгж нь хувиар.

Харьцуулалт	Зөрүү	95% интервал	Тайлбар
Нэгтгэсэн − Muse	$+3.5$	$[0.4, 6.9]$	Статистикийн хувь өссөн
Нэгтгэсэн − Gemma	$+4.8$	$[1.1, 8.7]$	Статистикийн хувь өссөн
Нэгтгэсэн − Qwen	-0.7	$[-3.7, 1.9]$	Тэгийг агуулсан

10,000 дахин түүвэрлэлт. Кессийг тогтмол гэж үзсэн түүврийн интервал.

Гурван загварын аль нэг нь зөв гаргасан утгыг сонгох боломжтой гэж үзсэн дээд хязгаар 84.6% байв. Үлдсэн 83/539 утгыг гурвуулаа зөрүүтэй гаргасан тул зөвхөн эдгээр гурван хариунаас сонгох аргаар уг зөрүүг арилгах боломжгүй. Мөнгөн дүнгийн дээд хязгаар 76.0%, дөрвөн мөнгөн дүн зэрэг зөв болох боломжтой мөр 26/49 байв.

Хүснэгт 14: Нэмэлт шалгалтын бүлэг тус бүрийн 11 баганын зөв хувь (%). Зүйлийн нэрийг товчилсон.

Бүлэг	N	Muse	Gemma	Qwen
17.3 Залилах[a]	5	78.2	78.2	80.0
17.1 Хулгайлах	5	81.8	85.5	85.5
17.8 Эд хөрөнгө устгах, гэмтээх	5	81.8	83.6	83.6
17.5 Алдаатай гүйлгээ, илгээмж завших	5	100.0	94.5	98.2
23.2 Хуурамч баримт бичиг	5	54.5	34.5	72.7
22.8 Төсвийн хөрөнгө завших	5	65.5	60.0	69.1
26.x Кибер орчны хэрэг	5	89.1	94.5	85.5
22.10 Үндэслэлгүйгээр хөрөнгөжих	5	52.7	50.9	43.6
18.15 Даатгалын нөхөн төлбөр	4	68.2	59.1	81.8
17.11 Болгоомжгүй устгах, гэмтээх	5	65.5	81.8	81.8

[a]17.3.2.1-ээс бусад заалт. Нэг шийдвэр олон зүйлээр хамт зүйлчлэгдсэн байж болно.

Бүлгээр авч үзэхэд 17.5-ийн таван шийдвэр дээр Muse 100.0%, Gemma 94.5%, Qwen 98.2% гарсан. Харин 22.10-ийн таван шийдвэр дээр харгалзах үзүүлэлт 52.7%, 50.9%, 43.6% байв. Эдгээр тоо нь тухайн түүврийн ялгааг харуулж байгаа бөгөөд бүх зүйл ангийн ерөнхий чанарын эрэмбэ гэж үзэхэд шийдвэрийн тоо хангалтгүй. Түүнчлэн 26.x бүлгийн шийдвэрүүд 17.1 эсвэл 17.3-тай хамт зүйлчлэгдсэн тул энэ бүлгийн өндөр оноог дан кибер төрлийн хэрэгт хамааруулж болохгүй.

EMPREL баганыг Muse 28/49, Gemma 34/49, Qwen 36/49 зөв гаргасан. Кессээс тухайн байгууллагын ажилтан биш гэж тэмдэглэсэн 36 шийдвэрээс ажилтан мөн гэж Muse 14, Gemma 7, Qwen 7 тохиолдолд гаргав. JOBACC=0 байсан 36 шийдвэрээс JOBACC=1 гэж гаргасан тоо тус тус 13, 6, 9 байлаа. Гэхдээ шинэ 49 шийдвэр дээр суурь загваруудтай харьцуулаагүй тул уг алдааг зөвхөн 17.4-ийн QLoRA сургалтаас үүссэн гэж тогтоох боломжгүй.

Мөнгөн дүнгийн зөрүүнээс 0 болон −1 хооронд солигдсон утга Muse-д 18, Gemma-д 19, Qwen-д 17 байв. Эдгээрийг алдаа гэж шууд үзээгүй бөгөөд энэ үнэлгээнд давхар хянасан кессийг хэвээр хэрэглэсэн. Цаашид алдааг эх бичвэрээр тайлбарлахдаа бодитоор тэг дүнтэй, мэдээлэл дутуу, тухайн хэрэгт хамаарахгүй нөхцөлийг ялгах шаардлагатай. Одоогийн M1 схемд сүүлийн хоёр нөхцөлийг тусдаа кодоор ялгадаггүй. Үндсэн 98 шийдвэр болон энэ 49 шийдвэрийн кессийг хянасан байдал, хэргийн бүрэлдэхүүн өөр тул хооронд онооны зөрүүг зөвхөн зүйл анги өөрчлөгдсөний нөлөө гэж тайлбарлаагүй.

5.5 Хэрэглээ

Энэхүү судалгааны үр дүнгээс харахад QLoRA-аар сургасан загвар хэдэн мянган шүүхийн шийдвэрээс олборлосон хүснэгт датаны эхний хувилбар үүсгэх, хүний хяналтыг өндөр эрсдэлтэй багана, мөр лүү чиглүүлэх туслах хэрэгсэл болгон ашиглах боломжтой. Muse-ийн бүх мөрийн зөв хувь 33.7%, Gemma-ийнх 41.8%, Qwen-ийнх 41.8%байгаа нь аль ч хувилбарыг хяналтгүйгээр эцсийн судалгааны өгөгдөл болгоход хангалтгүй байгааг харуулж байна. Харин форматын зөв хувь 100%, төлөв болон ангиллын баганууд 95%-аас дээш гарсан нь автомат урьдчилсан боловсруулалт болон дараагийн хяналтын дараалал үүсгэх хэрэглээнд боломж байгааг илтгэнэ.

Иймээс энэхүү системийг хүнийг бүрэн орлох олборлогч гэж бус, урт шүүхийн кессийг тогтмол хүснэгтэнд оруулж, зарим найдвартай багана дээр өгөгдөл олборлох хэрэгсэл болгон ашиглах нь зүйтэй. Мөн өөр богино гаралттай даалгаварууд дээр бага зардлаар ажлын 24GB VRAM-тай компьютер дээр QLoRA хийж ажлын бүтээмжийг нэмэгдүүлэх боломжтой гэж үзэж байна.

Цаашид энэхүү аргыг зөвхөн одоогийн судалгаанд ашигласан баганаудаар хязгаарлахгүйгээр, судалгааны асуултад тохирсон шинэ гаралтын схем тодорхойлон шүүхийн шийдвэрийн томоохон сангаас тоон судалгааны өгөгдөл үүсгэхэд ашиглаж болно. Тухайлбал, зээлийн маргаантай шийдвэрүүдээс зээлдэгчийн нас, ажил эрхлэлт, зээлийн хэмжээ, зээлдүүлэгчийн төрөл, барьцаа болон төлөгдөөгүй дүн зэрэг мэдээллийг олборлон ямар шинжтэй зээлдэгчид өр төлбөрийн маргаанаар шүүхэд хүрч байгааг судлах боломжтой. Үүнтэй адил хөдөлмөрийн маргаанаас ажилтны албан тушаал, салбар, ажлаас чөлөөлсөн үндэслэл, нэхэмжлэлийн төрөл болон шүүхийн үр дүнг ялган авч ямар төрлийн хөдөлмөрийн харилцаанд маргаан илүү үүсэж байгааг шинжилж болно. Мөн захиргааны хэргээс иргэн, аж ахуйн нэгж ямар төрлийн төрийн байгууллага, ямар шийдвэртэй холбоотойгоор шүүхэд хандаж байгаа болон тухайн шийдвэр хүчингүй болох нөхцөлийг судлах зэрэг хэрэглээ байж болно. Ийм төрлийн судалгаанд эхлээд шаардлагатай хувьсагчдыг тодорхойлж, дараа нь шүүхийн шийдвэрийн текстээс тэдгээрийг ижил бүтэцтэйгээр олборлох нь тухайн хугацааны бүхий л шийдвэрийг хамруулах боломж бүрдүүлнэ.

6 Дүгнэлт

Энэхүү судалгаагаар Монгол хэл дээрх эрүүгийн хэргийн анхан шатны шүүхийн шийдвэрээс хохирол, шийдвэрээс өмнөх төлөлт, үлдэгдэл, гаргуулах дүн, огноо болон албан тушаалтай холбоотой 13 баганатай нэг шийдвэрийг мөр болгон олборлох боломжийг QLoRA аргаар сургасан гурван том хэлний загвар дээр туршив. Muse-Glimmer-30B, Gemma-4 31B, Qwen3.8-27B загваруудын суурь жинг 4 битийн NF4 хэлбэрээр жижигрүүлж, $r = 8$ ранктай LoRA-г 500 жишээгээр сургахад гурван загварын сургалт нэг RTX 3090 24 GB GPU-ийн VRAM-д багтаж, сургах үед тус тус 4.69, 9.34, 15.66 цаг зарцууласан. Энэ нь 27–31B хэмжээтэй загварыг 10 мянга орчим токен урттай оролтоор хэрэглээний түвшний нэг GPU дээр тухайн даалгаварт тохируулах нь практикт хэрэгжих боломжтойг харуулж байна.

Шалгалтын 98 шийдвэр дээр QLoRA сургалтын дараа гурван загвар бүгд 100% формат зөв гаралт үүсгэж, 13 баганын зөв таамагласан хувь Muse, Gemma, Qwen-д тус тус 88.3%, 90.1%, 90.7%, бүх багана зөв мөрийн хувь 33.7%, 41.8%, 41.8% болсон. Суурь хувилбартай харьцуулахад 13 баганын үзүүлэлт Muse-д $+19.3\%$ өсөж итгэх интервал нь $[15.8, 23.0]$, Qwen-д $+15.4$ хувь ($[12.3, 18.5]$) өсөж, бүлгийн бутстрэп итгэх интервал тэгийг агуулаагүй. Хамгийн их сайжрал нь утгын хувьд хоорондоо төстэй багануудад гарсан: Muse-д RSTAT 32.7%-иас 91.8%, RECOV 26.5%-иас 70.4%, OUTST 36.7%-иас 78.6% болов. Иймээс QLoRA сургалт нь шийдвэрт дурдагдсан мөнгөн дүнг зөвхөн тоо болгон танихаас илүүтэй тухайн дүн нийт хохирол, өмнөх төлөлт, үлдэгдэл эсвэл гаргуулах дүнгийн аль нь болохыг ялгах чадварыг сайжруулсан гэж дүгнэж байна.

Харин сургасан загваруудын хоорондын ялгаа энэ түүврийн хүрээнд тогтвортой бус байна. Тухайлбал, Gemma ба Muse-ийн 13 баганын зөрүү $+1.8\%$, итгэх интервал нь $[-0.4, 3.9]$ байсан тул аль нэг загварыг ерөнхийдөө давуу гэж дүгнэх үндэслэлгүй. Гурван загварын хариуг багана тус бүрээр олонхын саналаар нэгтгэхэд 13 баганын зөв хувь 91.7%, бүтэн зөв мөр 46/98 болж бага зэрэг өссөн боловч бүтэн мөрийн өсөлтийн итгэх интервал тэгийг агуулсан.

Алдааны шинжилгээнээс харахад сул тал нь огноо болон мөнгөн дүнд төвлөрч байна. OEND ба CRECV-ийн зөв хувь гурван загварт 67–82% хооронд байсан бөгөөд зөрүүний ихэнх нь reference_label-д огноо тодорхойгүй (-1) гэж тэмдэглэсэн. Загварууд мэдээлэл байхгүй үед -1 сонгохын оронд ойролцоох огноог сонгох хандлагатай байв. Мөн нэг тохиолдолд шаардлагатай нотолгоо шийдвэрийн бүтэн эхэд байсан ч загварт өгсөн багцад ороогүй. Энэ нь алдааны нэг хэсэг загвараас бус, урьдчилсан боловсруулалтаас үүсэж болохыг харуулж байна. Сургалтад ороогүй өөр зүйл ангийн 49 шийдвэр дээр 11 баганын зөв хувь 72.5–78.1% болж, үндсэн шалгалтаас 10 гаруй нэгж хувиар буурсан. Бүлгээр нь харахад 17.5-д 94.5–100%, 22.10-д 43.6–52.7% байв. EMPREL ба JOBACC баганад ажилтан биш хэргийг ажилтан гэж үзэх алдаа ажиглагдсан. Иймээс сургасан загварын чанар нь сургалтын өгөгдөлтэй төстэй бүтэцтэй шийдвэрт хамгийн өндөр байгаа бөгөөд бусад төрлийн хэрэгт шилжүүлэхэд нэмэлт сургалт эсвэл хяналт шаардлагатай.

Эдгээр үр дүнг хэд хэдэн хязгаарлалтын хүрээнд тайлбарлах хэрэгтэй. Үнэлгээний жишиг нь бүрэн хүний баталгаатай тэмдэглэгээ бус reference_label юм. Сургалтыг нэг санамсаргүй эх утгаар хийсэн бөгөөд шалгалтын олонлог 98 жишээтэй. Мөн Muse-ийн суурь үнэлгээнд гаралтын эхлэлийг механикиар шийдсэн тул бусад загвартай бүрэн ижил биш юм.

Практик талаас нь авч үзвэл, QLoRA-аар сургасан загварыг шүүхийн шийдвэрийг хүнгүйгээр бүрэн автоматаар хүснэгтжүүлэх хэрэгсэл гэж үзэх боломжгүй. Учир нь хамгийн сайн хувилбарт ч 98 мөрийн тал орчим нь дор хаяж нэг баганад зөрүүтэй байна. Харин формат зөв гаралт тогтвортой, төлөв ба ангиллын багануудын 95% орчим зөв байгаа тул хэдэн мянган шийдвэрээс эхний шатны хүснэгт үүсгэх, хүний хяналтыг тодорхойгүй огноо, үлдэгдэл, өндөр дүнтэй хохирол зэрэг эрсдэлтэй багана, мөр лүү чиглүүлэх хэрэгсэл болгон ашиглах нь бодитой хувилбар юм.

Илүү дэвшилтэд ухаалаг суурь модел ашиглан хийгдвэл ижил арга зүйг зээл, хөдөлмөр, захиргааны маргаан зэрэг өөр төрлийн шийдвэрт шинэ гаралтын схемээр өргөтгөж, бодлого боловсруулагч ба судлаачдад зориулсан бүтэцлэгдсэн өгөгдлийн эх сурвалж бий болгох боломжтой.

Ашигласан бүтээл

[1] E. J. Ху, Y. Шэнь, P. Уоллис, Z. Аллен-Жу, Y. Ли, S. Ван, L. Ван, and W. Чэнь, *LoRA: Low-Rank Adaptation of Large Language Models*, 2021. https://arxiv.org/abs/2106.09685.

[2] T. Дэттмерс, A. Паньони, A. Холцман, and L. Зеттлмойер, *QLoRA: Efficient Finetuning of Quantized LLMs*, 2023. https://arxiv.org/abs/2305.14314.

[3] J. Ли, R. Бхамбхория, and X. Жу, "Parameter-Efficient Legal Domain Adaptation," *Proceedings of the Natural Legal Language Processing Workshop*, pp. 119–129, 2022.

[4] PyTorch contributors, "Scaled dot product attention, PyTorch 2.11 documentation." https://docs.pytorch.org/docs/2.11/generated/torch.nn.functional.scaled_dot_product_attention.html.

[5] I. Халкидзис, M. Фергадиотис, P. Малакасиотис, N. Алетрас, and I. Андруцопулос, "LEGAL-BERT: The Muppets straight out of Law School," *Findings of EMNLP*, pp. 2898–2904, 2020.

[6] Y. Чэнь, Y. Сунь, Z. Ян, and H. Линь, "Joint Entity and Relation Extraction for Legal Documents with Legal Feature Enhancement," *Proceedings of COLING*, pp. 1561–1571, 2020.

[7] P. Каламкар, A. Агарвал, A. Тивари, S. Гупта, S. Карн, and V. Рагхаван, "Named Entity Recognition in Indian Court Judgments," *Proceedings of the Natural Legal Language Processing Workshop*, pp. 184–193, 2022.

[8] G. Халтархүү, B. Батжаргал, and A. Маэда, "Text Classification of Modern Mongolian Legal Documents Using BERT Models," *International Journal of Asian Language Processing*, 33(3):2350020, 2023.

[9] G. Халтархүү, B. Батжаргал, and A. Маэда, "Recognizing Textual Inference in Mongolian Bar Exam Questions," *Applied Sciences*, 14(3):1073, 2024.

[10] B. Батжаргал, G. Халтархүү, and A. Маэда, "Named Entity Extraction from digitized texts of Mongolian Historical Documents in Traditional Mongolian Script," *Digital Humanities 2016: Conference Abstracts*, pp. 734–735, 2016.

[11] H.-H. Хуан, C.-H. Чан, K.-C. Чиен, and J.-C. Кун, "Information extraction in legal texts: Investigating LLMs' performance on traffic accident verdicts," *Computer Law & Security Review*, 61:106313, 2026.

[12] H.-H. Хуан, C.-H. Чан, K.-C. Чиен, and J.-C. Кун, "Information Extraction in Legal Texts: Investigating LLMs' Performance on Traffic Accident Verdicts," *JURISIN 2025 Local Proceedings*, pp. 1–16, 2025.

[13] Монгол Улс, *Хүний хувийн мэдээлэл хамгаалах тухай хууль*. https://legalinfo.mn/mn/detail?lawId=16390288615991.

[14] Цахим хөгжил, харилцаа холбооны сайд, *Цахим хэлбэрээр боловсруулалт хийх технологийг ашиглан мэдээлэл цуглуулж, боловсруулж, ашиглах үйл ажиллагаанд үнэлгээ хийх журам*, 2023 оны 9 дүгээр сарын 1, A/81.

[15] Судалгааны кесс сангийн таталтын бүртгэл, *17.4 болон "Хөдөлмөрийн" тулхүүр үгийн хайлт*, 2019-01-01–2026-08-03. Хадгалсан таталтын бүртгэл, индекс, 69 API хуудас. кесс систем: https://shuukh.mn/cases/2/1.

7 Хавсралт

7.1 Сайжруулах боломж ба хязгаарлалт

Энэхүү судалгаанд хэд хэдэн хязгаарлалт байна. Нэгдүгээрт, reference_label зөвхөн 99 жишээг бие даан хянасан тэмдэглэгээтэй бөгөөд анхны тэмдэглэгээний (annotation) гарал үүсэл бүрэн сэргээгдээгүй. Иймээс 88.3%, 90.1%, 90.7%зэрэг үзүүлэлт нь баримтын абсолют зөв таамагласан байдлыг бус, хадгалсан баталгаа өндөр ялгасантай (reference label) зөв таасан хувийг хэмжинэ. Хоёрдугаарт, шалгалтын олонлог 98 жишээ, 93 бүлэгтэй бөгөөд сургалтыг санамсаргүй нэг эх утгаар (random seed) хийсэн. Gemma болон Qwen-ийг нэмэх үед Muse-ийн шалгалтын үр дүн аль хэдийн харагдсан тул бүх загварын туршилтыг бүрэн урьдчилан бүртгэсэн (pre-registered), өмнө нь хараагүй шинэ шалгалт гэж үзэх боломжгүй.

Иймээс цаашдын судалгаанд баталгаа өндөр ялгасанг бүрэн хүний хяналтаар баталгаажуулах, шинэ цаг хугацаа эсвэл шинэ хэргийн бүлгээр тусгаарласан шалгалтын олонлог бэлтгэх, мөнгөн дүнгийн үнэмлэхүй алдаа (absolute error) болон их хэмжээний хохирлыг тусад нь хэмжих үзүүлэлт ашиглах, мөн тодорхойгүй огноонд хангалттай итгэлгүй үед хоосон утга буцаах буюу “мэдээлэлгүй” төлөвийг сонгох чадварыг сайжруулах шаардлагатай. Гурван загварыг ижил шалгалтын олонлог дээр харьцуулсан хэдий ч үр дүнгийн тогтвортой байдлыг өөр санамсаргүй эх утга, шинэ шалгалтын өгөгдөл болон ижил механик угтварын нөхцөлтэй суурь загвараар дахин шалгах нь дараагийн шатны гол ажил болно.

Тус судалгаанд нийтэд нээлттэй Шүүхийн шийдвэрийн цахим санд нийтлэгдсэн шийдвэрүүдийг ашигласан боловч мэдээлэл нийтэд нээлттэй байх нь хувийн мэдээлэлтэй холбоотой эрсдэл байхгүй гэсэн үг биш. Монгол Улсын Хүний хувийн мэдээлэл хамгаалах тухай хууль болон хүний оролцоогүй цахим боловсруулалтын үнэлгээний журамд мэдээлэл цуглуулах, боловсруулах, ашиглахтай холбоотой шаардлагууд тусгагдсан [13, 14]. Иймээс өгөгдлийн сан, хэрэг тус бүрийн түүхий эх болон LoRA адаптерыг нийтэд түгээхээс өмнө шүүхийн шийдвэрийн цахим сангийн ашиглах нөхцөл, нууцлал, өгөгдлийг цээжлэх (memorization) эрсдэл болон эмзэг тэмдэгт мөр задрах эрсдэлийг тусад нь хянах шаардлагатай.

7.2 Мөнгөн дүн дээрх алдаа

Muse-ийн сургасан хувилбарын алдааны тархалтыг шинжлэхэд 33 мөр алдаагүй, 27 мөр нэг, 14 мөр хоёр, 12 мөр гурван баганад зөрүүтэй, үлдсэн 12 мөр дөрөв буюу түүнээс олон баганад зөрсөн байна. Алдаатай 65 мөрийн 27 буюу 41.5%нь ганц баганын зөрүүтэй байв. Иймээс 88.3%-ийн баганын зөв таалтын хувь харьцангуй өндөр боловч алдаа ихэнхдээ ганц баганад төвлөрсөн гэж дүгнэх боломжгүй.

Мөнгөн дүнтэй баганууд буруу таасан тохиолдлыг авч үзэхэд 65 мөр зөрүүгүй, 8 мөр нэг, 14 мөр хоёр, 9 мөр гурав, 2 мөр дөрвөн зөрүүтэй байв. Түүнчлэн 0 утгатай жишээг зөв таамагласан байдал нь мөнгөн дүнгийн ерөнхий үнэлгээнд нөлөөлж байна. OUTST-ийн баталгаат утга 0 байсан 43 жишээ бүгд зөв гарсан бол үлдэгдэлтэй 52 жишээний 32 буюу 61.5%нь зөв таарсан. RECOV-ийн дүнтэй 76 жишээний 49 буюу 64.5%зөв байв. Эдгээр үр дүн нь нийт зөв таалтын хувиас гадна мөнгөн дүнгийн алдаа болон үнэмлэхүй зөрүүг тусад нь үнэлэх шаардлагатайг харуулж байна.

Практик хэрэглээний хувьд LOSS, RECOV, OUTST, AWARD-ийг тусад нь хадгалснаар хохирлын хэмжээ, шийдвэр гарах хүртэлх төлөлт болон үлдэгдлийг ялган шинжлэх боломжтой. Гэвч шүүхээс мөнгө гаргуулахаар шийдвэрлэсэн дүн нь бодит төлөлттэй адил биш бөгөөд шийдвэр гарах хүртэл төлсөн дүнг эцсийн буцаан авалт гэж үзэх боломжгүй. Иймээс загварын гаралтыг санхүүгийн тооцоонд шууд ашиглахаас өмнө өндөр дүнтэй болон утгын хувьд эрсдэлтэй мөрүүдийг хүний хяналтаар баталгаажуулах шаардлагатай.

7.3 Огноо нь тодорхойгүй үед

Огнооны алдааг шинжлэхэд зөрүүний ихэнх хэсэг баталгаа өндөр ялгасанд тодорхойгүй буюу -1 гэж тэмдэглэсэн жишээнүүдэд төвлөрч байна. Muse OEND-ийн өдөр тодорхой 72 жишээний 64 буюу 88.9%-ийг зөв гаргасан боловч OEND=-1 байсан 26 жишээний зөвхөн 2 буюу 7.7%-ийг зөв таньсан. CRECV-ийн өдөр тодорхой 60 жишээний 59 буюу 98.3%зөв байсан бол CRECV=-1 байсан 38 жишээний 8 буюу 21.1%зөв байв. OEND-ийн 32 зөрүүний 24, CRECV-ийн 31 зөрүүний 30 нь баталгаат утга -1 байсан жишээнд гарсан.

Gemma мөн тодорхойгүй огноонд алдаа гаргасан боловч Muse-ээс илүү олон -1 төлөвийг зөв таньсан. OEND=-1 байсан 26 жишээнээс 10, CRECV=-1 байсан 38 жишээнээс 20-ийг зөв гаргасан. Харин өдөр нь өгөгдсөн OEND дээр Gemma 62/72, Muse 64/72; CRECV дээр Gemma 54/60, Muse 59/60 байв. Туршилтын үр дүнгээс харахад огнооны нийт дундаж үзүүлэлт нь бүх төрлийн огноо таних чадварыг ижил хэмжээгээр илэрхийлэхгүй байна. Иймээс мэдээлэлгүй төлөвийг ялгах чадварыг тусад нь үнэлэх шаардлагатай.

Нэг бодит жишээнд шаардлагатай OEND-ийн нотолгоо шийдвэрийн бүтэн эхэд байсан боловч загварт өгсөн багцад ороогүй. Энэ нь алдааны шалтгаан зөвхөн загварын унших чадвараар хязгаарлагдахгүй, урьдчилсан боловсруулалтын үеийн мэдээлэл сонголттой холбоотой байж болохыг харуулж байна. Иймээс цаашдын хувилбарт багц үүсгэгчийн хувилбарын дугаар, хэш (hash) утга болон тэмдэглэгээний гарал үүслийн (provenance) мэдээллийг хэрэг бүртэй хамт хадгалах шаардлагатай.

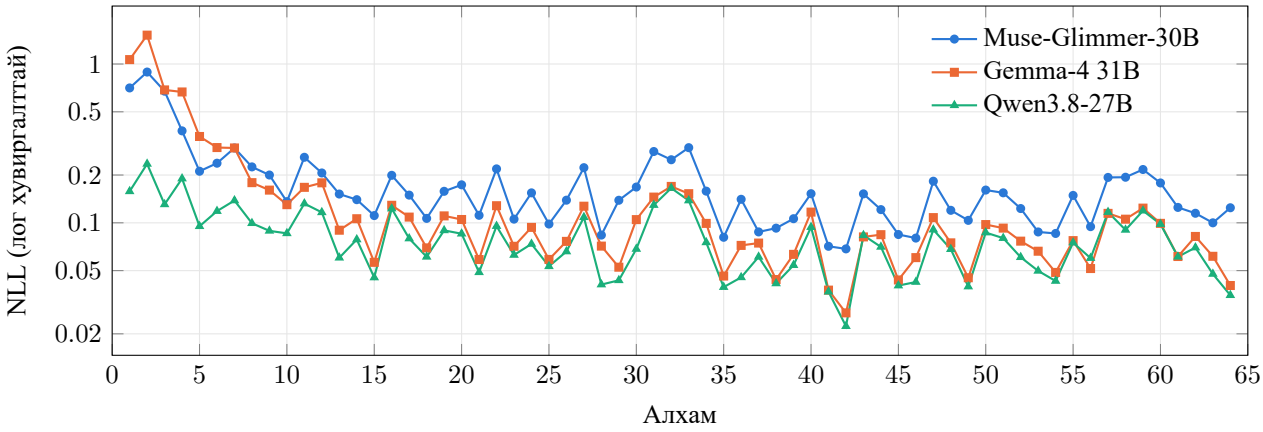
7.4 Токенчлогч

Хүснэгт 15: Гурван загварын токенчлолаар ижил 657 жишээг хэмжсэн урт (токен). Сургалт, үнэлгээнд ашигласан чатын загвар ба хариуны төгсгөлийн токеныг яг тэр хэлбэрээр оруулсан.

Үзүүлэлт	Muse-Glimmer-30B	Gemma-4 31B	Qwen3.8-27B
Токенчлол			
Үгийн сангийн хэмжээ	202,048	262,144	248,077
Чатын загварын нэмэлт токен[a]	56	13	12
Загваргүй текст (657 жишээ)			
Заавар (3,302 тэмдэгт, бүгдэд ижил)	1,419	1,786	1,862
Багц токен: медиан / дээд	2,687 / 7,486	3,419 / 8,394	3,661 / 8,711
Багц: нэг токенд ногдох тэмдэгт	2.47	1.95	1.82
Багц токен / Muse-гийнх[b]	1.00	1.27	1.36
Гаралт M1 мөр: медиан / дээд	39 / 44	67 / 86	67 / 86
Сургалтын дараалал ($N = 500$)			
Промпт: медиан / 90-р перцентиль	4,160 / 4,753 / 8,128	5,214.5 / 5,919 / 9,363	5,532 / 6,298 / 9,959
Хяналттай хариу[c]: медиан / дээд	43 / 47	68 / 86	68 / 86
Нийт: медиан / 90-р перцентиль / дээд	4,204 / 4,790 / 8,171	5,282 / 5,995 / 9,431	5,601.5 / 6,374 / 10,027
`max_seq_length`	9,216	9,431	10,027
Үнэлгээний ролт (промпт токен)			
Хөгжүүлэлт ($N = 59$): медиан / дээд	4,170 / 4,894	5,260 / 6,385	5,581 / 6,718
Шалгалт ($N = 98$): медиан / дээд[d]	4,142 / 8,961	5,203.5 / 10,193	5,508 / 10,585

[a]Промтын токен хасах хэрэглэгчийн текстийн токен; [b]Жишээ бүрийн харьцааны медиан. [c]Muse: `to=user<|message|>` + M1 + `<|eot|>`; Gemma: M1 + `<turn|>`; Qwen: M1 + `<|im_end|>`. [d]`max_seq_length` нь зөвхөн сургалтад хамаарна. 90-р перцентиль нь эрэмбэлсэн утгын $\lfloor 0.9N \rfloor$-р байрлал (0-ээс).

7.5 Оптимизацийн алхмаас хамаарах NLL-ийн динамик



Ижил токенчлолтой биш тул шууд харьцуулах боломжгүй. Санамсаргүй эх утга: 20260921